Centre d'Immunologie et des Maladies Infectieuses

SIPHIF

Inserm

UE IA et « Omiques »

INTRODUCTION

Dr Alexandre Godmer
Dr Guillaume Bachelot
Pr Antonin Lamazière

AP-HP. Sorbonne Université

SORBONNE UNIVERSITÉ

Contexte (1) : l'intelligence artificielle pour tous ?

Santé numérique : des radiologues bientôt au chômage ?

Inria

THE CONVERSATION

L'expertise universitaire, l'exigence journalistique

Une IA, juge de beauté des poissons tropicaux

[ne IA, juge de beauté des poissons tropicaux | CNRS Le journal]

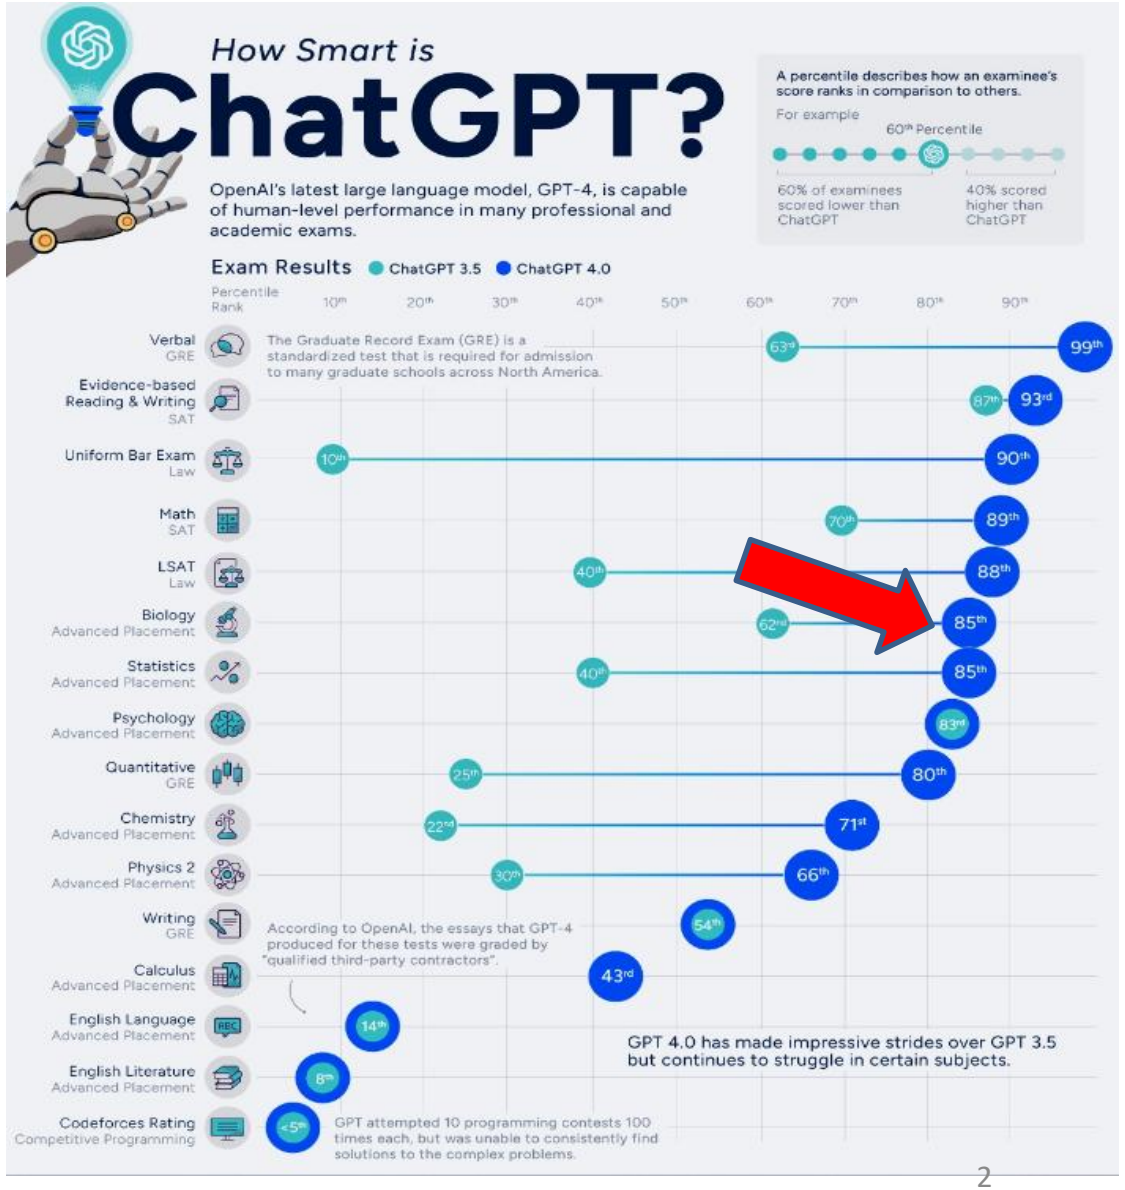

Dr A. Godmer

Contexte (2) : mais en fait…

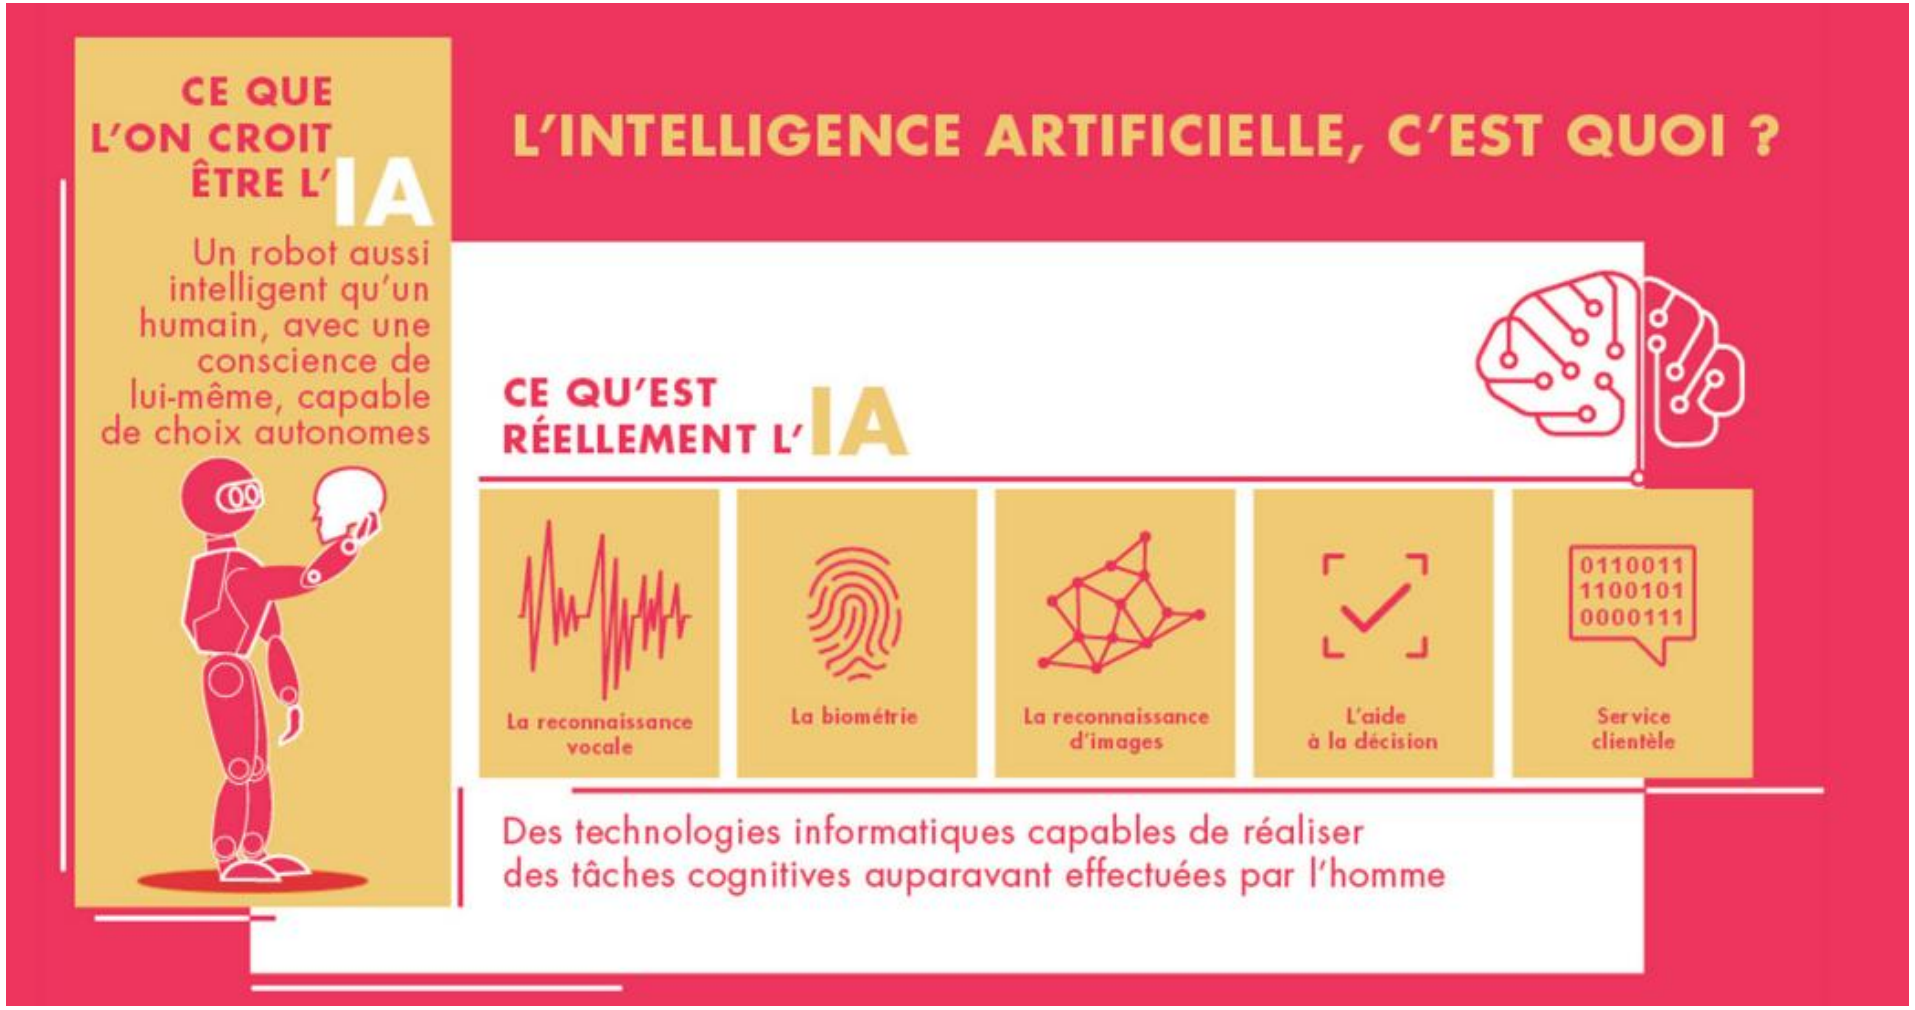

revue_personnel_-s._benhamou-_intelligence_artificielle.pdf (strategie.gouv.fr)

Contexte (3) : pourquoi a-t-on besoin de l'intelligence artificielle ?

- **Augmentation de la production de données massives hétérogènes = big data**
  limites de certains logiciels pour la gestion des données (excel)

- **Intelligence artificielle :**
  - pour l'analyse, tri des données de données massives
  - effectue des tâches répétitives
  - travaille en continu
  - création de systèmes de prédiction en santé

  → diminution du taux d'erreur
  → aide au diagnostic

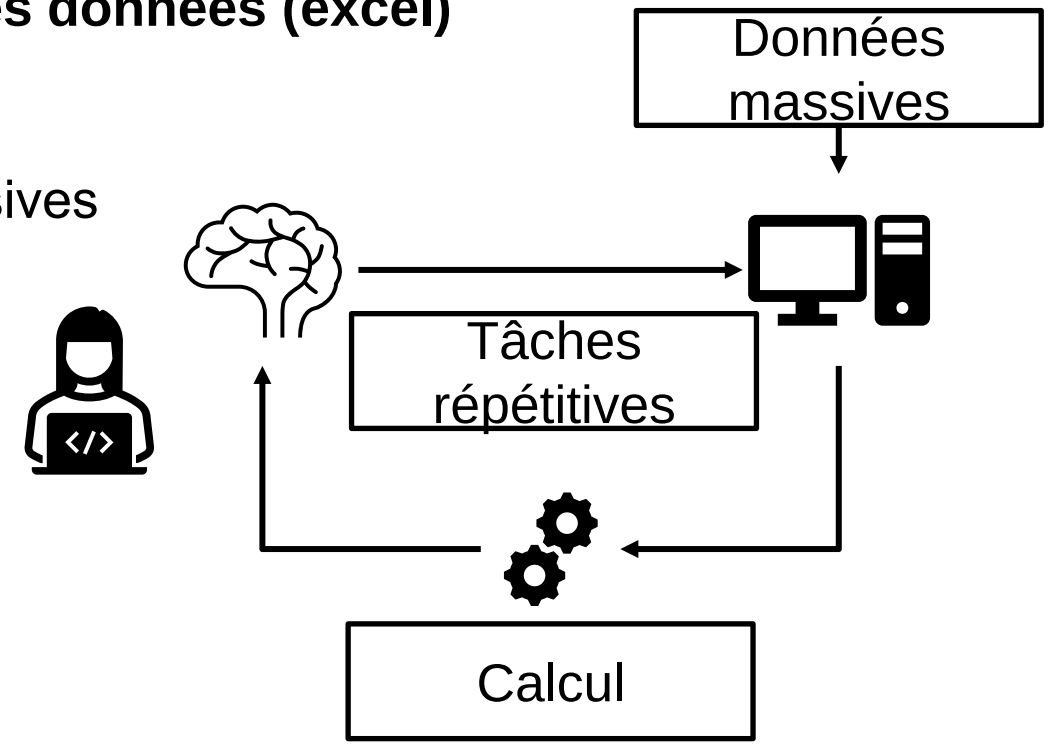

cerveau et intelligence artificielle = collaboration utile !

Contexte (3) : pourquoi a-t-on besoin de l'intelligence artificielle ?

- **Augmentation de la production de données massives hétérogènes = big data**
  limites de certains logiciels pour la gestion des données (excel)

- **Intelligence artificielle :**
  - pour l'analyse, tri des données de données massives
  - effectue des tâches répétitives
  - travaille en continu
  - création de systèmes de prédiction en santé

  → diminution du taux d'erreur
  → aide au diagnostic

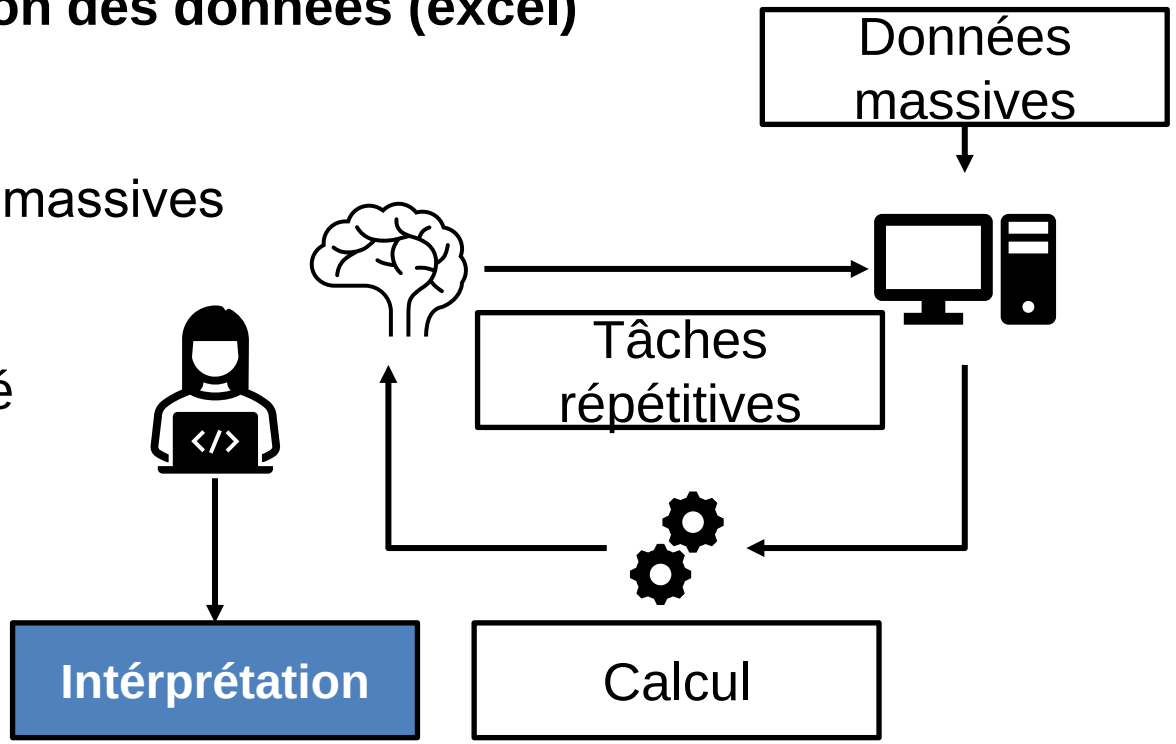

cerveau et intelligence artificielle = collaboration utile !

Contexte (4) : l'ère du Big Data

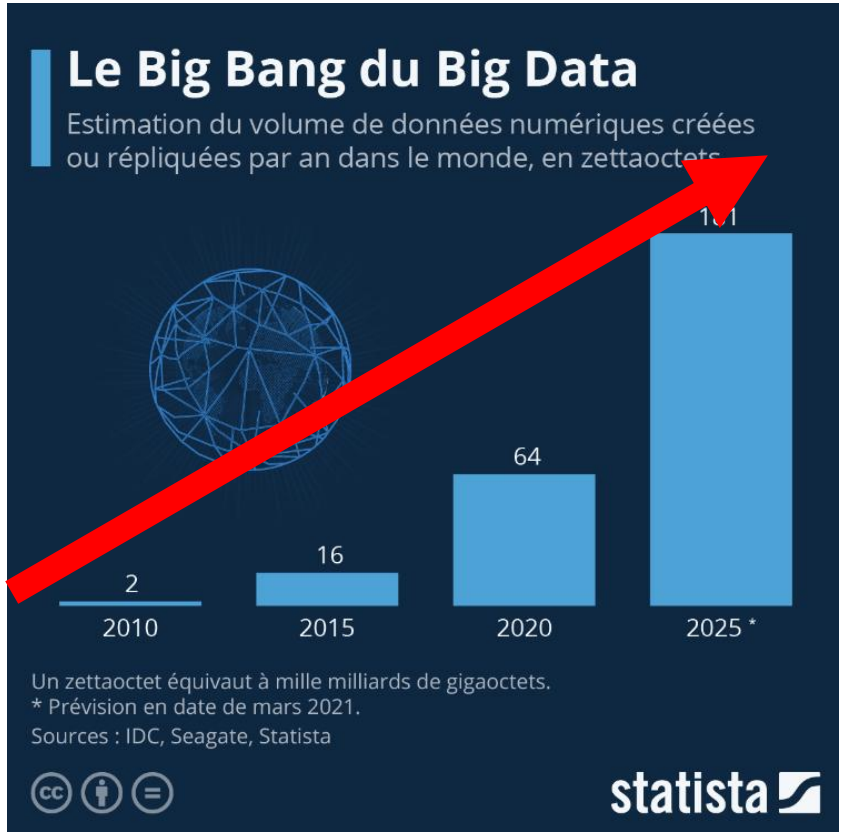

Graphique: Le Big Bang du Big Data | Statista

En santé

- **nouvelle compréhension des mécanismes des maladies**
- **recherche biomédicale axée sur les données massives**
- **computationnelle**
- **intégrative (de façon globalisée)**

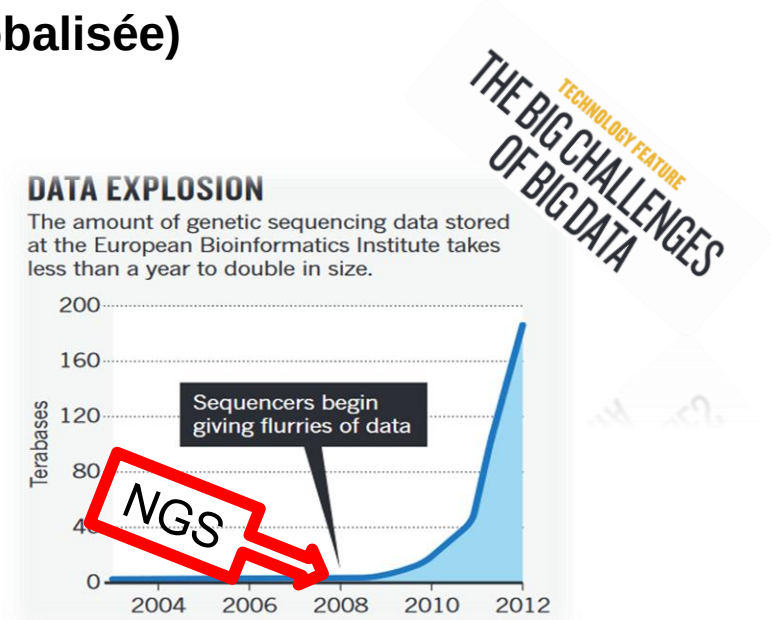

Marx, V. The big challenges of big data. *Nature* **498**, 255–260 (2013). https://doi.org/10.1038/498255a

Big Data
« stockage, agencement et traitement de de données massives hétérogènes »

Contexte (5) : l'ère du Big Data

Les caractéristiques des Big Data :

- volume :

→ considérable et en augmentation constante

- vitesse :

→ données collectées en temps réel

- variété :

→ données hétérogènes

- valeur :

→ quelle valeur ajoutée ?

→ pertinence

- véracité :

→ fiabilité des données

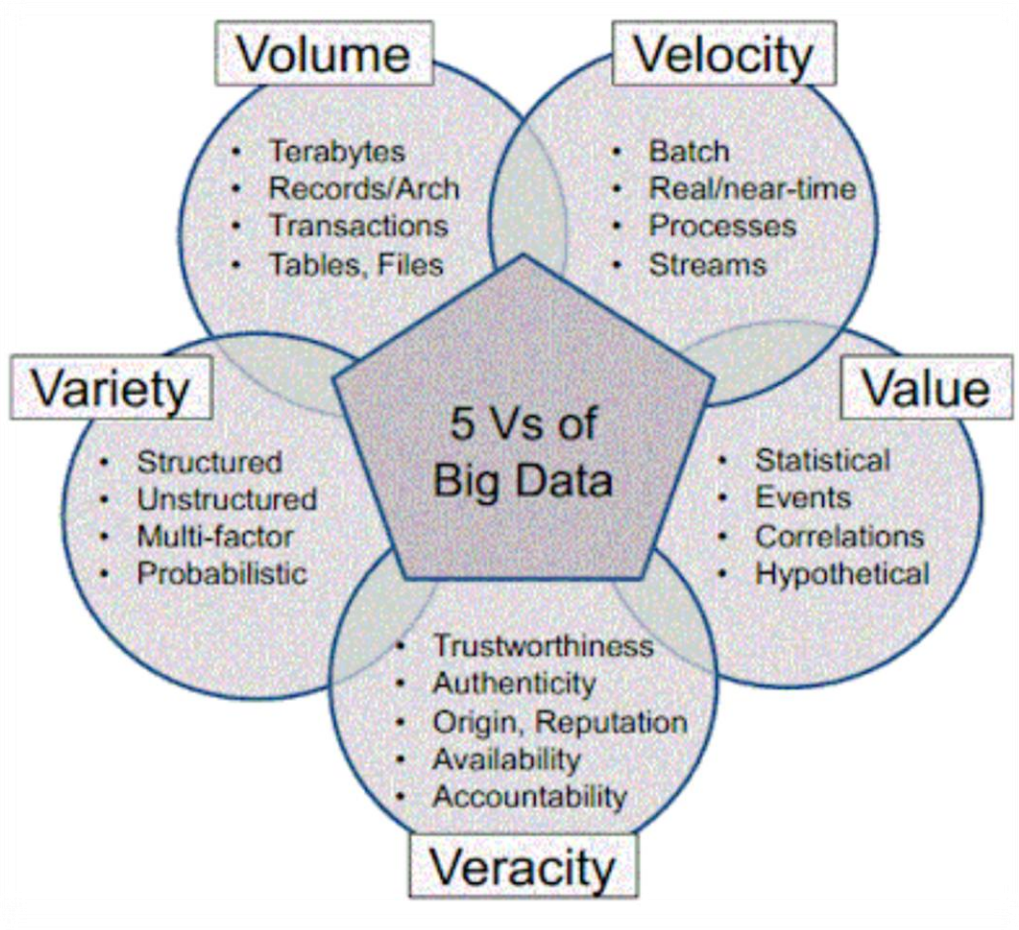

Marx, V. The big challenges of big data. *Nature* **498**, 255–260 (2013). https://doi.org/10.1038/498255a

Domaine de la santé : importance de la véracité des données +++

Contexte (5) : l'ère du Big Data

Les caractéristiques des Big Data :

- volume :

→ considérable et en augmentation constante

- vitesse :

→ données collectées en temps réel

- variété :

→ données hétérogènes

- valeur :

→ quelle valeur ajoutée ?

→ pertinence

- véracité :

→ fiabilité des données

Nettoyage et vérification des données

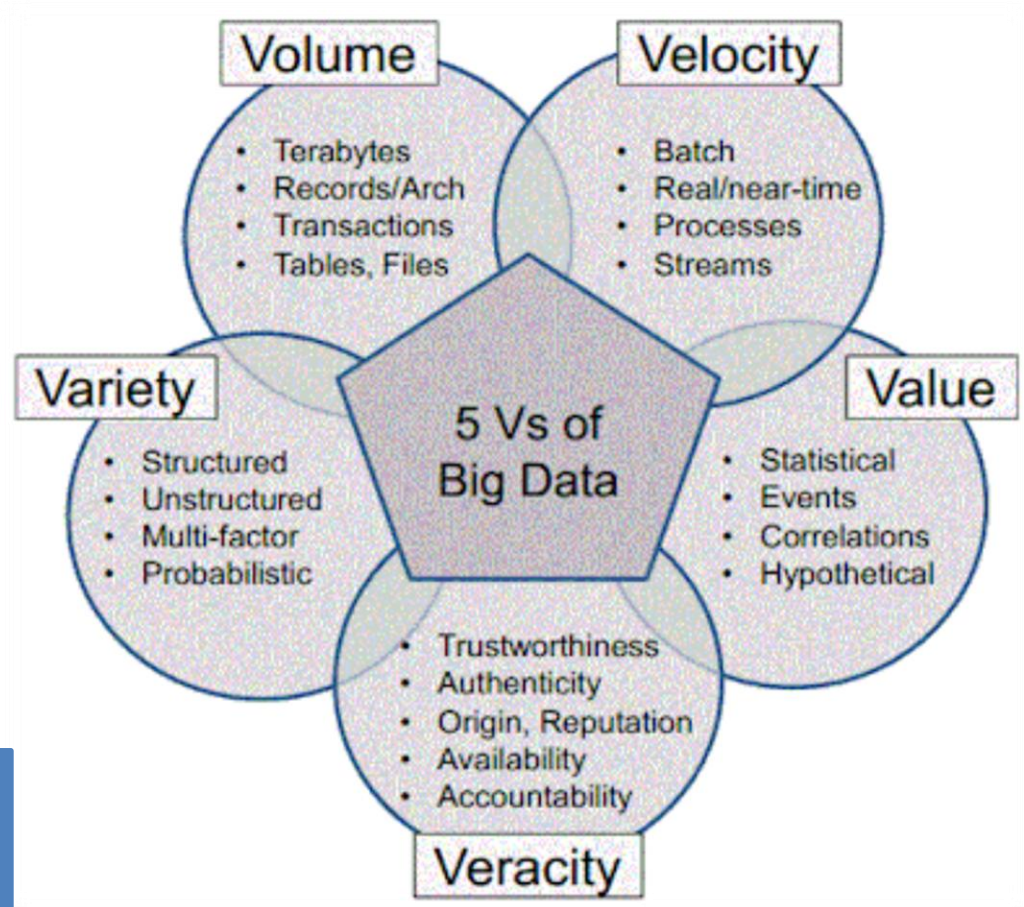

Marx, V. The big challenges of big data. *Nature* **498**, 255–260 (2013). https://doi.org/10.1038/498255a

Domaine de la santé : importance de la véracité des données +++

Contexte (6) : Big data et outils de gestions

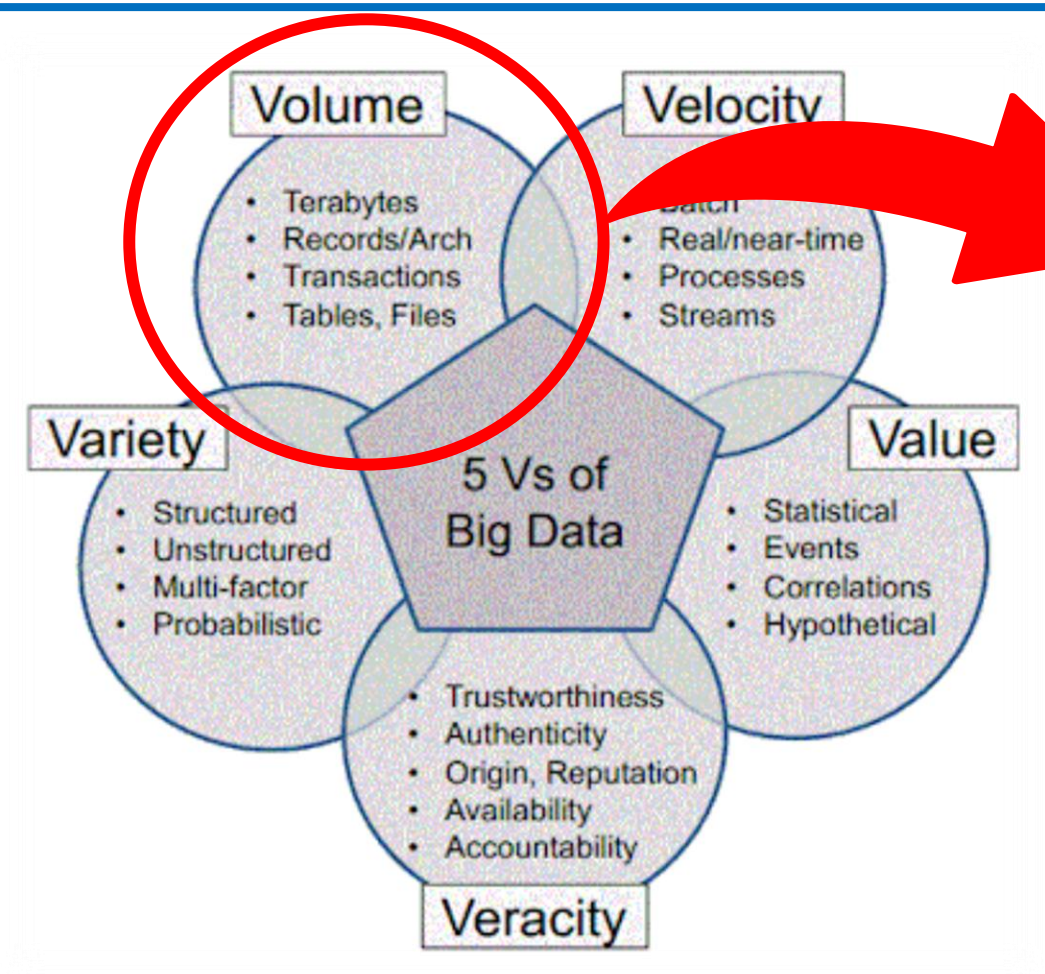

Marx, V. The big challenges of big data. *Nature* **498**, 255–260 (2013). https://doi.org/10.1038/498255a

ASSISTANCE PUBLIQUE HÔPITAUX DE PARIS
Entrepôt de Données de Santé

L'Entrepôt de Données de Santé de l'AP-HP, le plus gros entrepôt de données de santé hospitalier en Europe, contient aujourd'hui les données de plus de 11 millions de patients. Il appuie plus de 60 projets de recherche et d'innovation.

https://eds.aphp.fr/nos-services/recherche-innovation

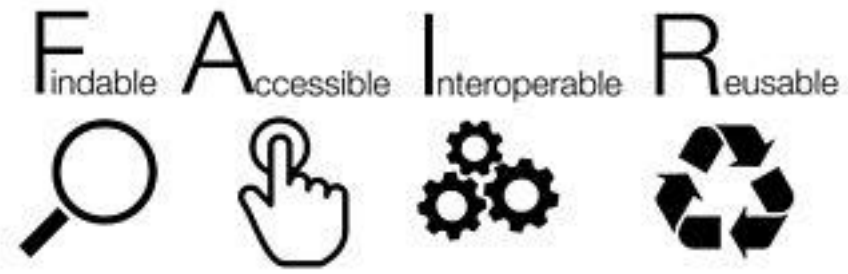

https://fr.wikipedia.org/wiki/Fair_data#/media/Fichier:FAIR_data_principles.jpg

Domaine de la santé :
principe FAIR et sécurité des informations médicales +++

Contexte (7) : La santé numérique (e-santé, eHealth) :

- **Définition (OMS) (https://www.who.int/observatories/global-observatory-for-ehealth) :**
  « eHealth is the use of information and communication technologies (ICT) for health »
- **Englobe de nombreuses technologies faisant appel à la programmation informatique (codage) :**
  - **Intelligence Artificielle (IA)**
  - Appareils connectés
  - Applications mobiles (mHealth)
  - …

Year	Total Number of FDA Approved Algorithms
2014	1
2015	0
2016	4
2017	8
2018	25
2019 (as of June)	8
Total (as of June 2019)	46

Source: The Medical Futurist (6 June 2019) FDA Approvals For Smart Algorithms In Medicine In One Giant Infographic.

The rise of the data-driven physician. Stanford Medicine 2020 Health Trends Report. 2020. URL: https://med.stanford.edu/dean/healthtrends.html

Echelard JF, Méthot F, Nguyen HA, Pomey MP. Medical Student Training in eHealth: Scoping Review. JMIR Med Educ. 2020 Sep 11;6(2):e20027. doi: 10.2196/20027. PMID: 32915154; PMCID: PMC7519432.

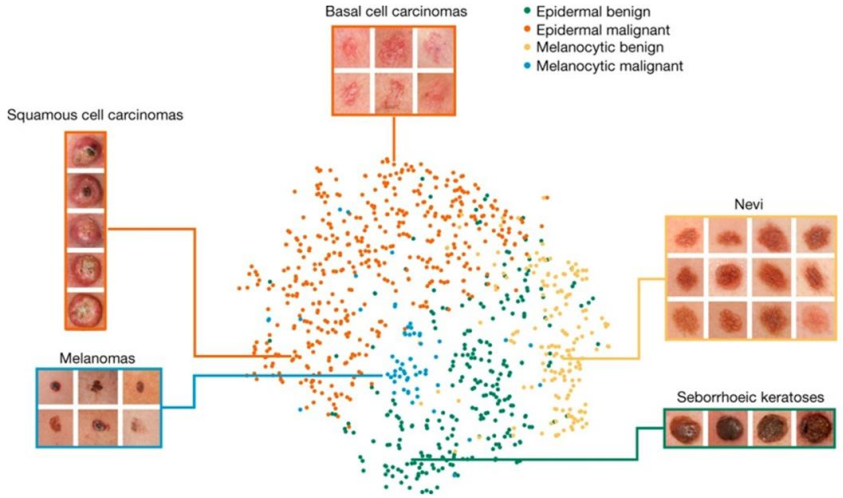

Esteva A, Kuprel B, Novoa RA, Ko J, Swetter SM, Blau HM, Thrun S. Dermatologist-level classification of skin cancer with deep neural networks. Nature. 2017 Feb 2;542(7639):115-118. doi: 10.1038/nature21056. Epub 2017 Jan 25. Erratum in: Nature. 2017 Jun 28;546(7660):686. PMID: 28117445; PMCID: PMC8382232.

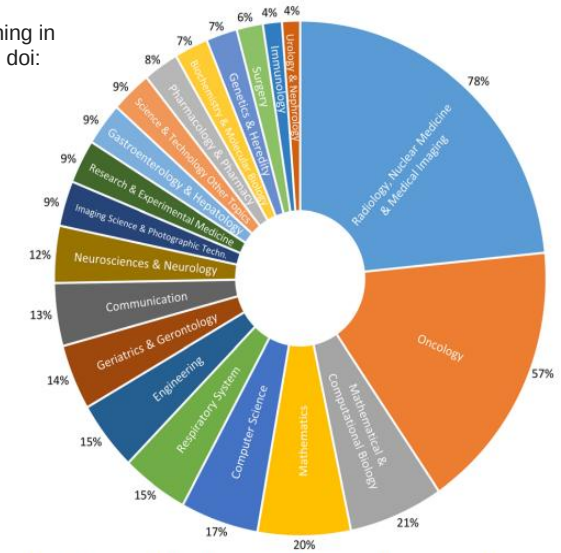

Fig. 3 Share of 3009 radiomics publications in the clinical and technical research areas assigned by the Web of Science for 2011 to 2019. Multiple assignments of research areas per publications are possible (see Supplement for further details on the methods)

Bukowski, M., Farkas, R., Beyan, O. *et al.* Implementation of eHealth and AI integrated diagnostics with multidisciplinary digitized data: are we ready from an international perspective?. *Eur Radiol* **30**, 5510–5524 (2020). https://doi.org/10.1007/s00330-020-06874-x

Intelligence artificielle = domaine en pleine expansion dans la santé

Contexte (8) : Intégration de l'IA dans les laboratoires

Echantillons

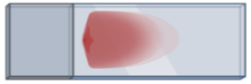

Production des données

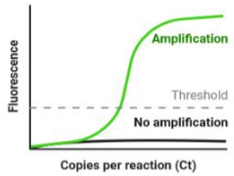

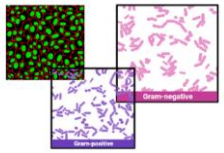

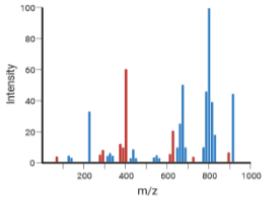

Numérisation des données (digitalisation)

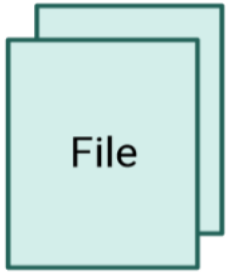

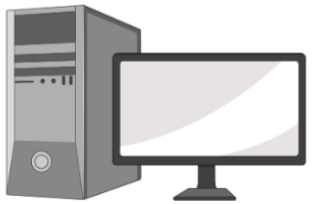

Algorithmes d'intelligence artificielle

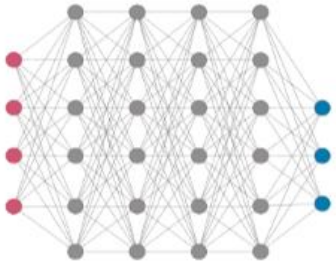

Systèmes d'aide au diagnostic

Dr A. Godmer

Take-Home message

Le Machine Learning est idéal pour :

- **Les problèmes pour lesquels les solutions existantes nécessitent beaucoup de règles et d'ajustement manuels**
- **Les problèmes complexes pour lesquels il n'existe pas de bonne solution en utilisant une approche traditionnelle (basées sur les règles, modèles mathématiques explicites…)**

L'intelligence artificielle (IA) en 3 définitions

Intelligence artificielle

"The use of computers to perform human-like tasks such as learning, perception and problem solving"

Machine Learning

"Field of study that gives computers the ability to learn without being explicitly programmed"

Deep Learning

"Extension of machine learning which use artificial neuronal network"

Arthur L. Samuel, 1959

https://cs.stanford.edu/memoriam/professor-arthur-samuel

Echelard JF, Méthot F, Nguyen HA, Pomey MP. Medical Student Training in eHealth: Scoping Review. JMIR Med Educ. 2020 Sep 11;6(2):e20027. doi: 10.2196/20027. PMID: 32915154; PMCID: PMC7519432.

IA et ordinateur

?????

Inputs :
x = 1
y = 2

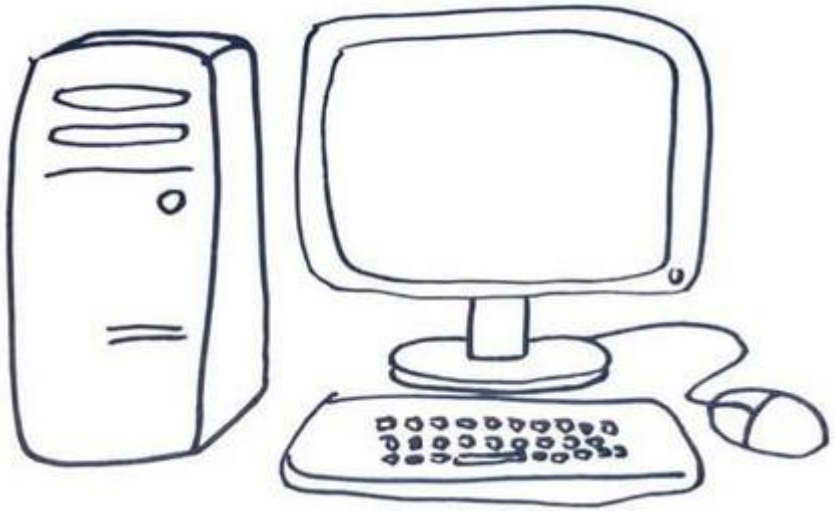

Output :
1

Algorithme

Algorithme

Inputs :
x = 1
y = 2

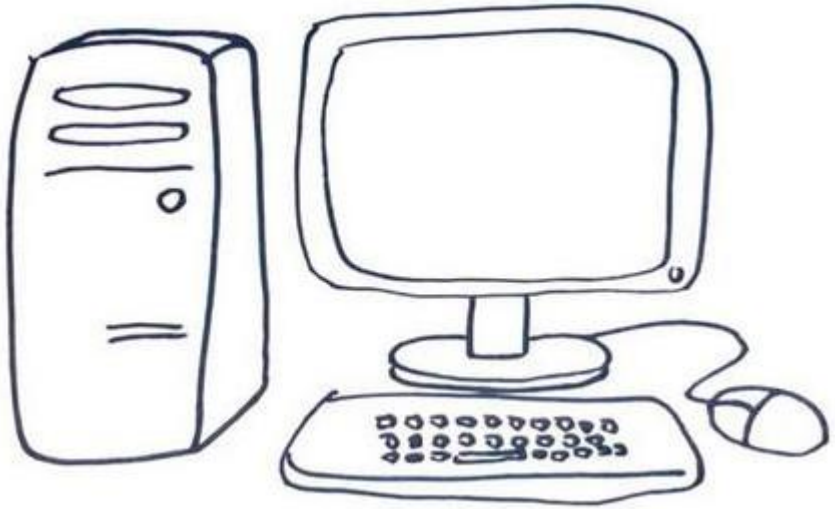

Output :
1

« Ensemble **de règles opératoires** dont l'application permet de **résoudre un problème** énoncé au moyen **d'un nombre fini d'opérations**. Un algorithme peut être traduit, grâce à un langage de programmation, en un programme exécutable par un ordinateur. »
Définition « algorithme », Larousse, 2020

Machine Learning, quelques concepts et vocabulaire

Régression : variable continue

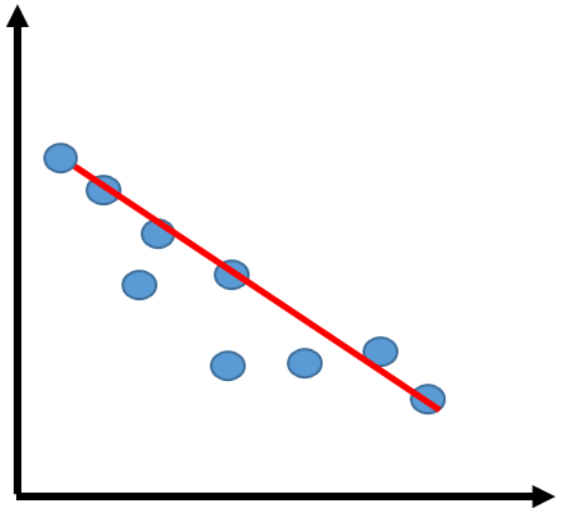

Classification variable discrète

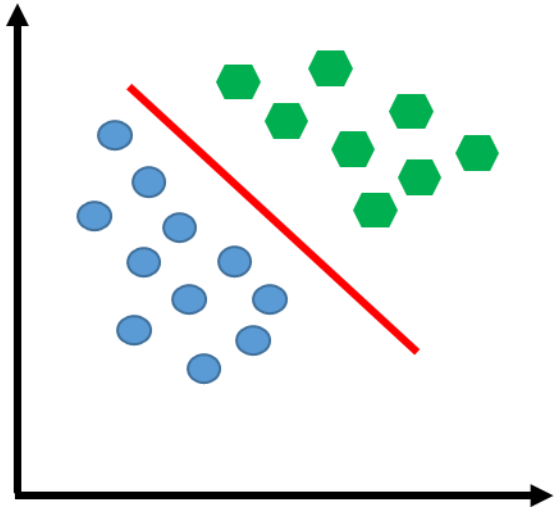

Machine Learning, quelques concepts et vocabulaire

- **Apprentissage supervisé :**
  - apprendre à partir d'exemples étiquetés (**labellisées**)
  - exemple : réseau de neurones, support vector machine (SVM)

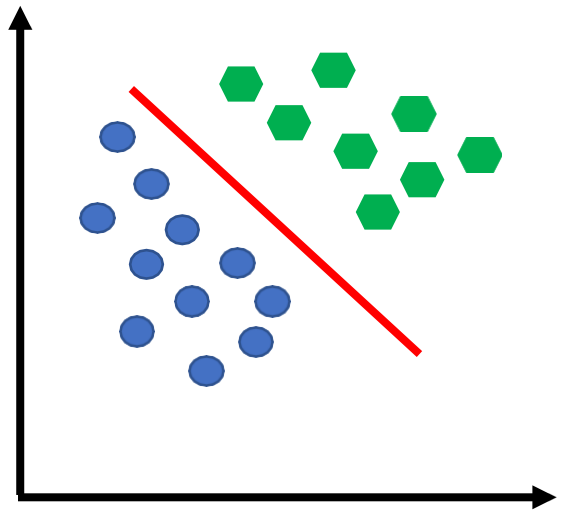

- **Apprentissage non supervisé :**
  - données non étiquetées
  - reconnaissance de structures propres au données
  - exemple: analyse composante principale (ACP), clustering

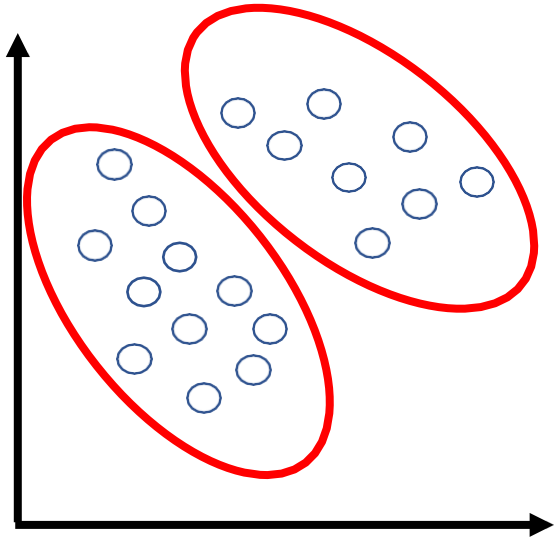

Machine Learning, un exemple simple

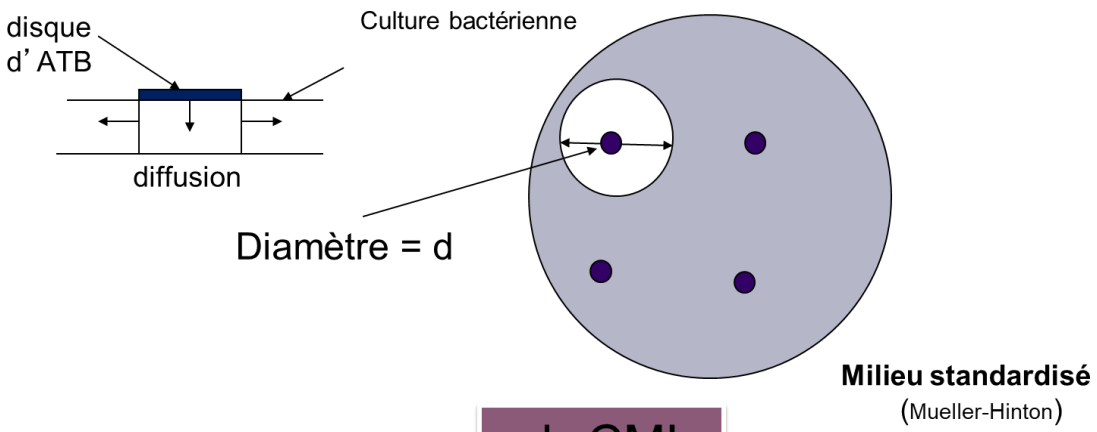

d↔CMI

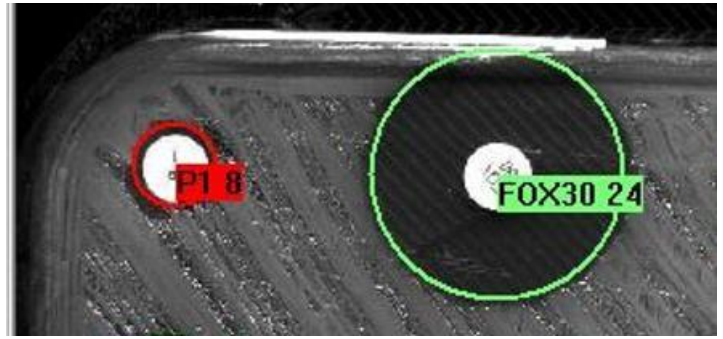

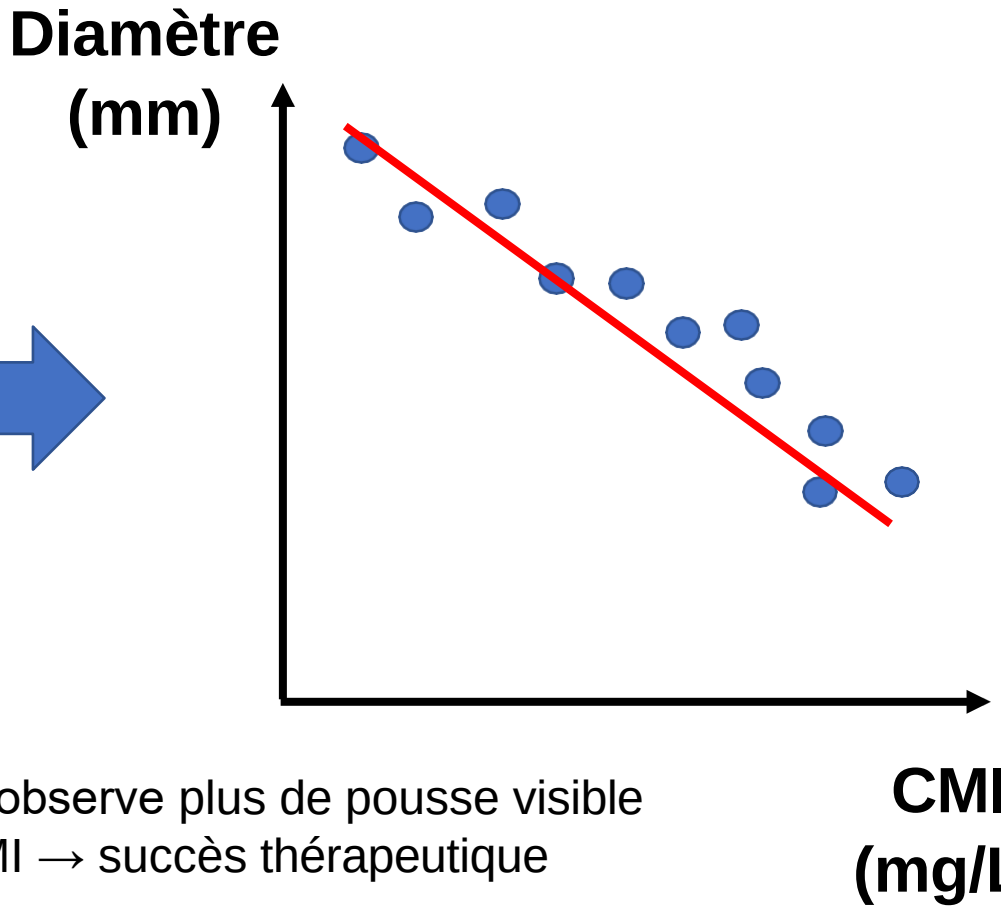

CMI : concentration minimale inhibitrice à partir de laquelle on n'observe plus de pousse visible
Objectif : concentration en antibiotique au site de l'infection > CMI → succès thérapeutique

Peut-on estimer la CMI (mg/mL) à partir du diamètre mesuré (mm) ?
Exemple avec IA = apprentissage supervisé et régression

Dr A. Godmer

Machine Learning, un exemple simple

Input ou feature (x) = diamètre du disque 31 mm

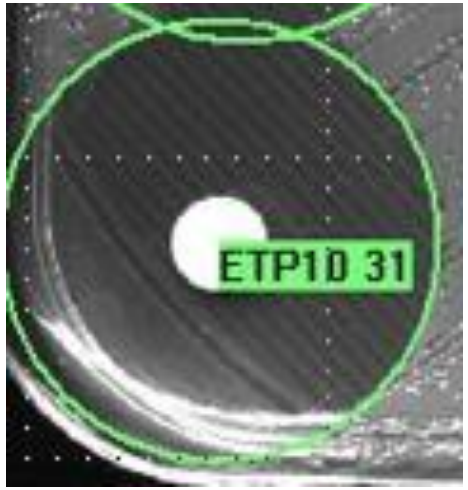

Equation du modèle
y = a(x) +b

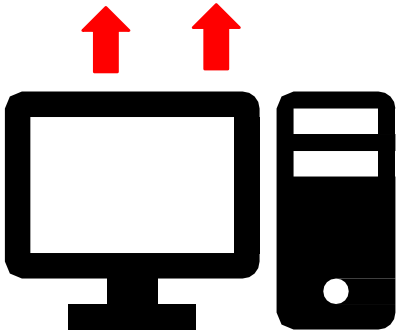

Calcul

CMI (vraie)
0,25 mg/L

Output (y) = CMI

?

Il faut déterminer les meilleurs paramètres (a) et (b) de l'équation du modèle → entraînement du modèle

Machine Learning, un exemple simple

Input ou feature (x) = diamètre du disque 31 mm

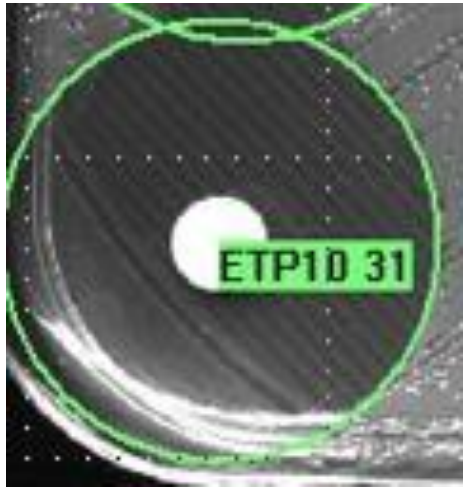

Equation du modèle
y = a(x) +b

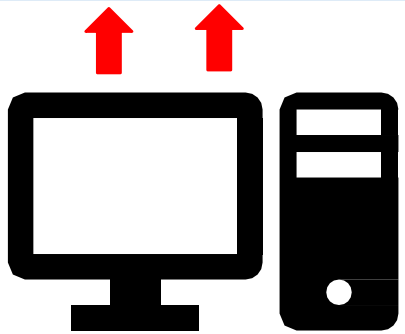

Calcul

CMI (vraie)
0,25 mg/mL

Output (y) = CMI
4 mg/mL

Mesure de l'erreur entre l'output et la CMI (vraie)
(fonction de perte)

Machine Learning, un exemple simple

Input ou feature (x) = diamètre du disque 31 mm

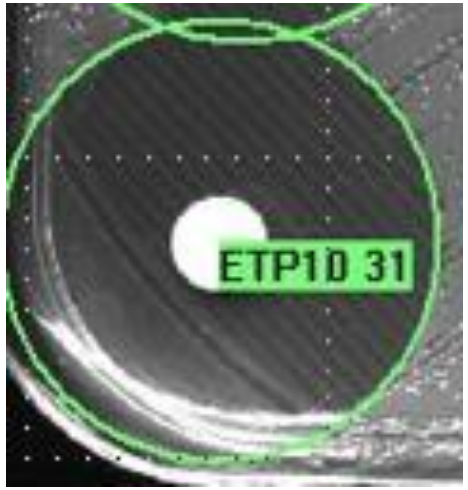

Equation du modèle
y = a(x) +b

Calcul

CMI (vraie)
0,25 mg/mL

Output (y) = CMI
4 mg/mL

Mesure de l'erreur entre l'output et la CMI (vraie)

Ajustement des paramètres du modèle

Machine Learning, un exemple simple

Equation du modèle
y = a(x) +b

CMI (vraie)
0,25 mg/mL

Input ou feature (x) = diamètre du disque 31 mm

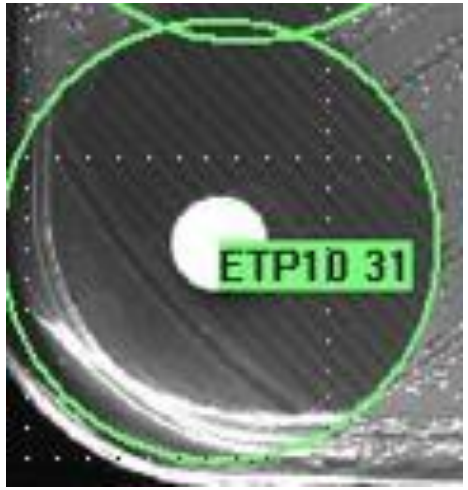

Output (y) = CMI
0,25 mg/mL

Calcul

Mesure de l'erreur entre l'output et la CMI (vraie)

Ajustement des paramètres du modèle

$$Performance = tâche \times expérience$$

Machine Learning, exemples d'algorithmes

Forêts aléatoires
Random forests (RF)

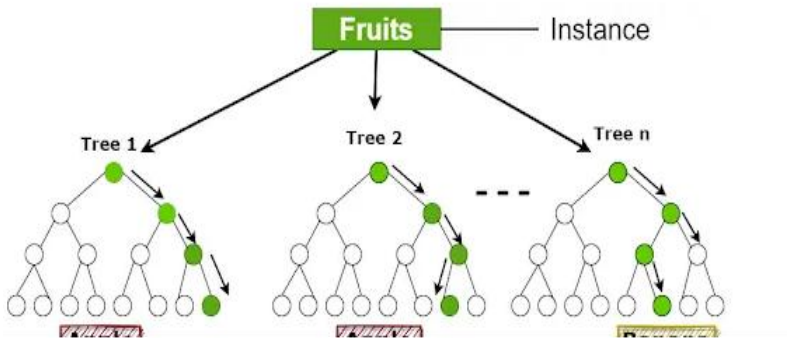

Machines a support de vecteur
Support vector machine (SVM)

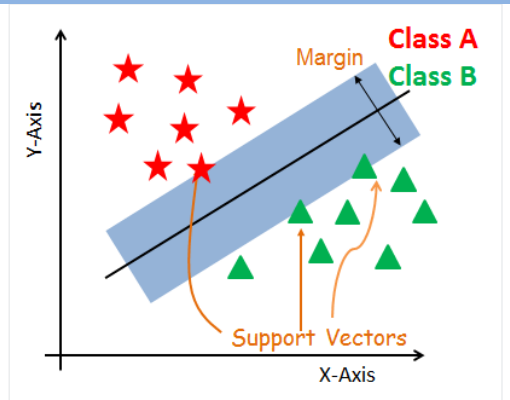

Machine Learning

« Domaine d'étude qui donne aux ordinateurs la capacité d'apprendre sans être explicitement programmés. »

Deep Learning

Extension de l'apprentissage automatique qui utilise un réseau neuronal artificiel

Analyse discriminante linéaire
Linear discriminant analysis (LDA)

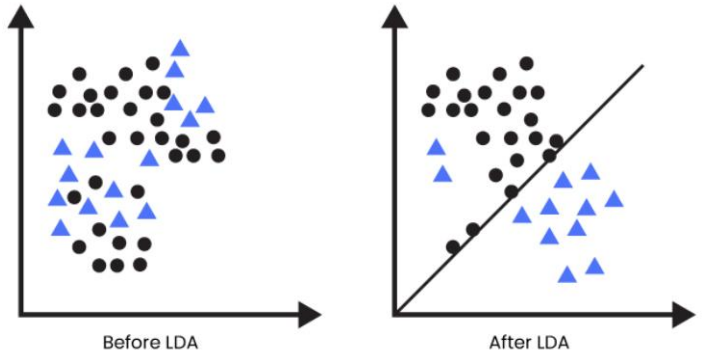

Réseau de neurones artificiels

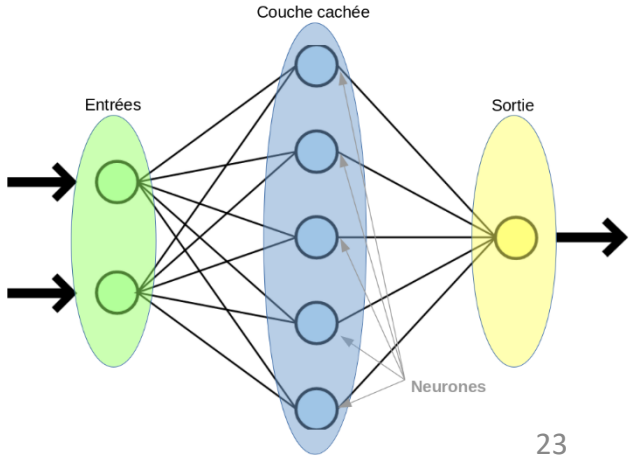

https://www.datacamp.cor
https://www.analyticssteps.com/blogs/introduction-linear-discriminant-analysis-supervised-learning

Machine Learning, méthodologie

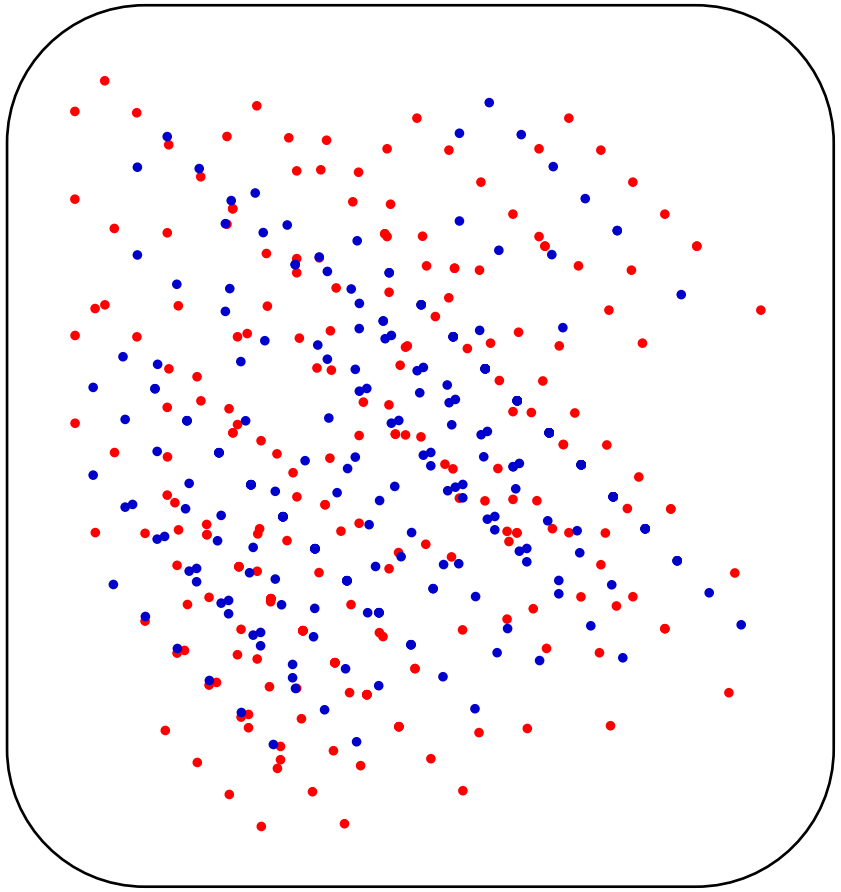

Base de données

Machine Learning, méthodologie

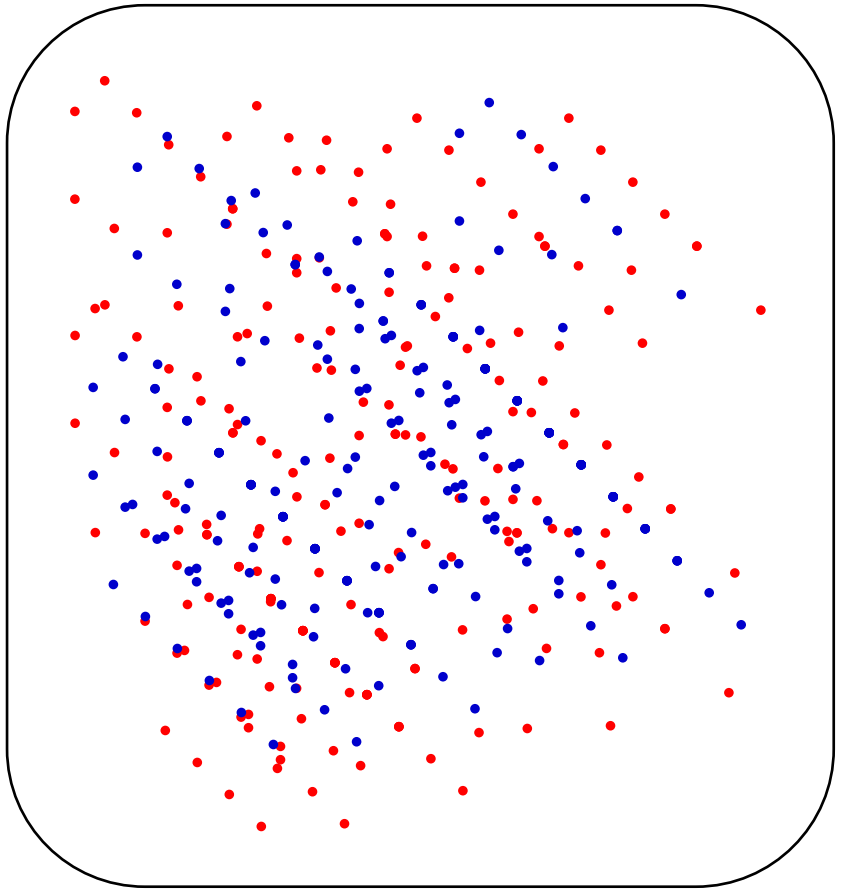

Base de données

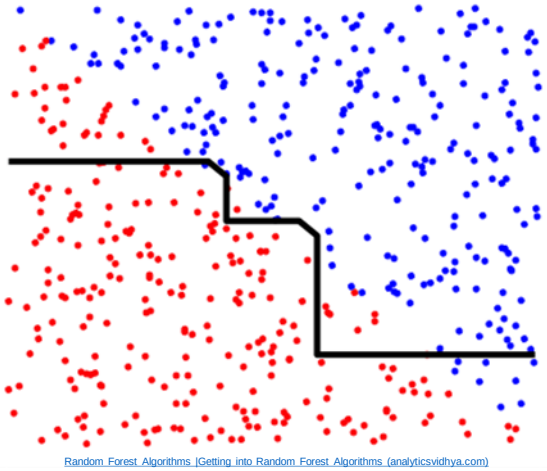

Entraînement

Algorithme

Machine Learning, méthodologie

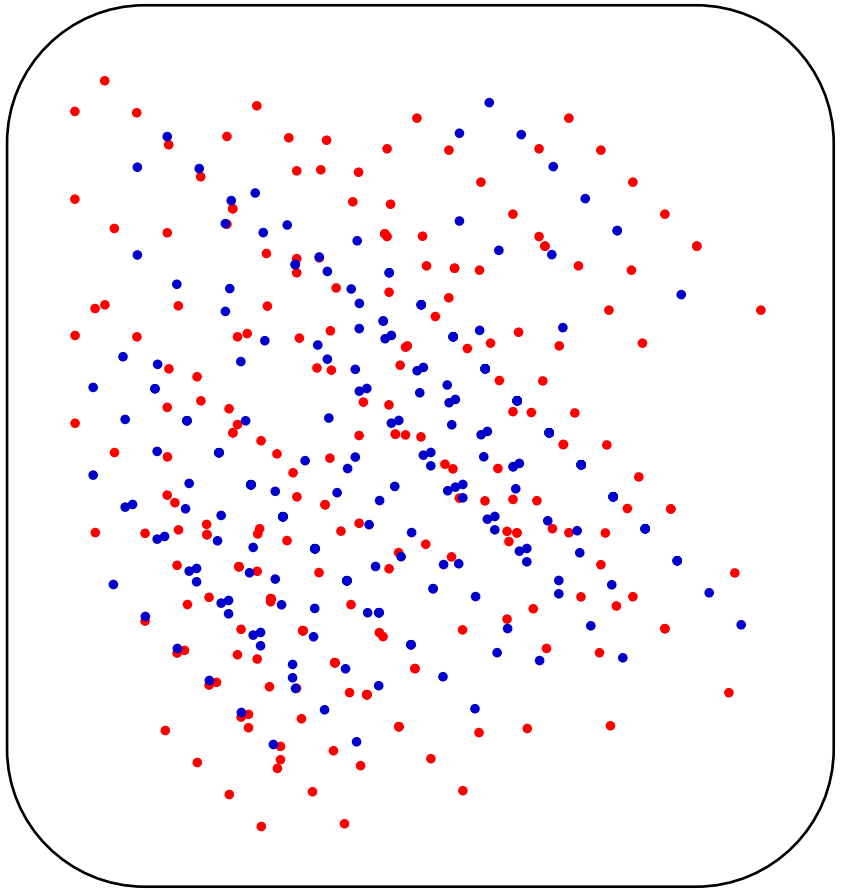

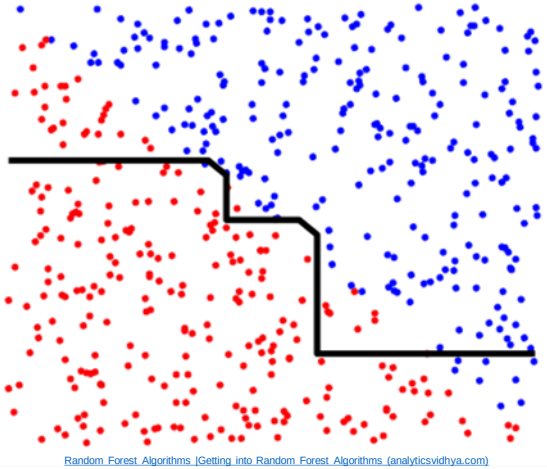

Entraînement

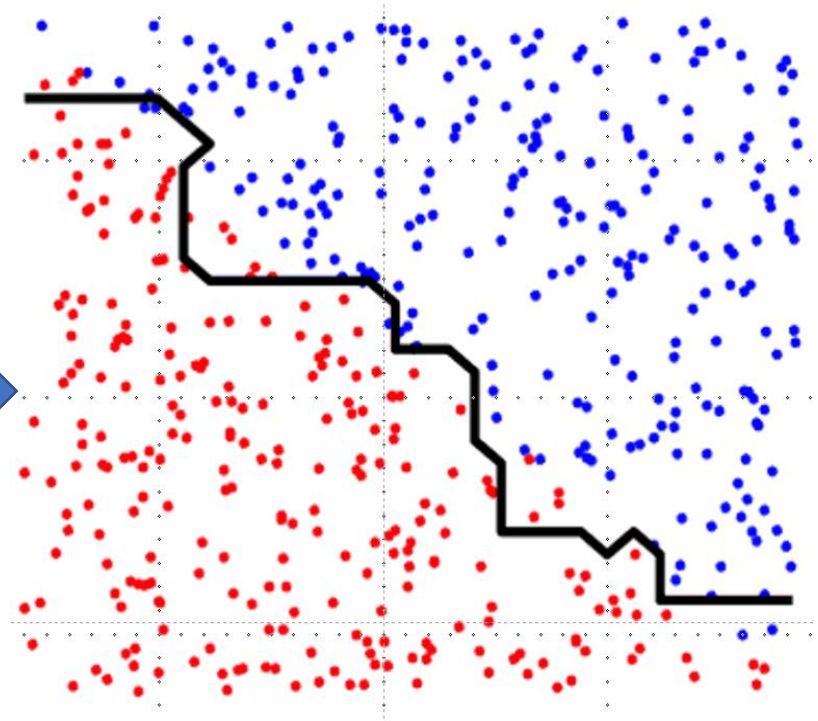

Base de données

Algorithme

Estimation/classification

Systèmes informatiques capables d'apprendre et d'améliorer leurs performances de façon autonome

Dr A. Godmer

Machine Learning, fonction de perte et de coût

Least squared	Logistic	Hinge	Cross-entropy
$\frac{1}{2}(y-z)^2$	$\log(1+\exp(-yz))$	$\max(0,1-yz)$	$-\left[y\log(z)+(1-y)\log(1-z)\right]$
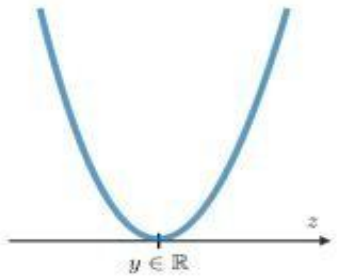	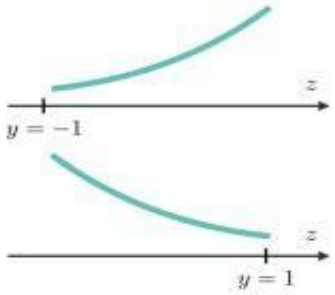	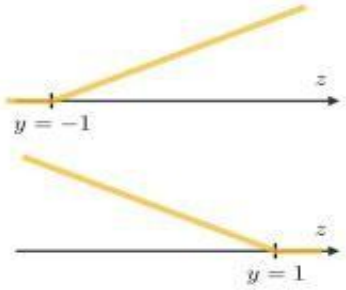	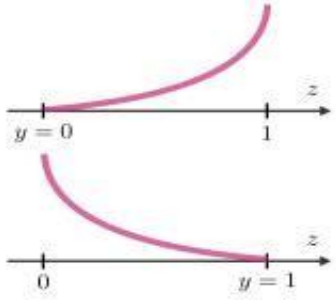
Linear regression	Logistic regression	SVM	Neural Network

D'après Hichem Felouat - hichemfel@gmail.com - Algeria

- La fonction de perte : calcule l'erreur pour un seul exemple
- La fonction de coût est la moyenne des fonctions de perte du jeu d'entrainement

Machine Learning, matrice de confusion

		Résultats du test de référence (gold standard)		
		Positif	**Négatif**	
Test diagnostique	**Positif**	Vrais positifs (VP)	Faux positifs (FP)	→ Valeur prédictive positive (VPP) = VP/(VP + FP)
	Négatif	Faux négatifs (FN)	Vrais négatifs (VN)	→ Valeur prédictive négative (VPN) = VN/(FN + VN)
		↓ Sensibilité = VP/(VP + FN)	↓ Spécificité = VN/(FP + VN)	

$$Accuracy\ (classification\ binaire) = \frac{Vrai\ positif + Vrai\ négatif}{Vrai\ négatif\ +\ Faux\ positif\ +\ Vrai\ positif\ +\ Faux\ négatif}$$

Machine Learning, vocabulaire

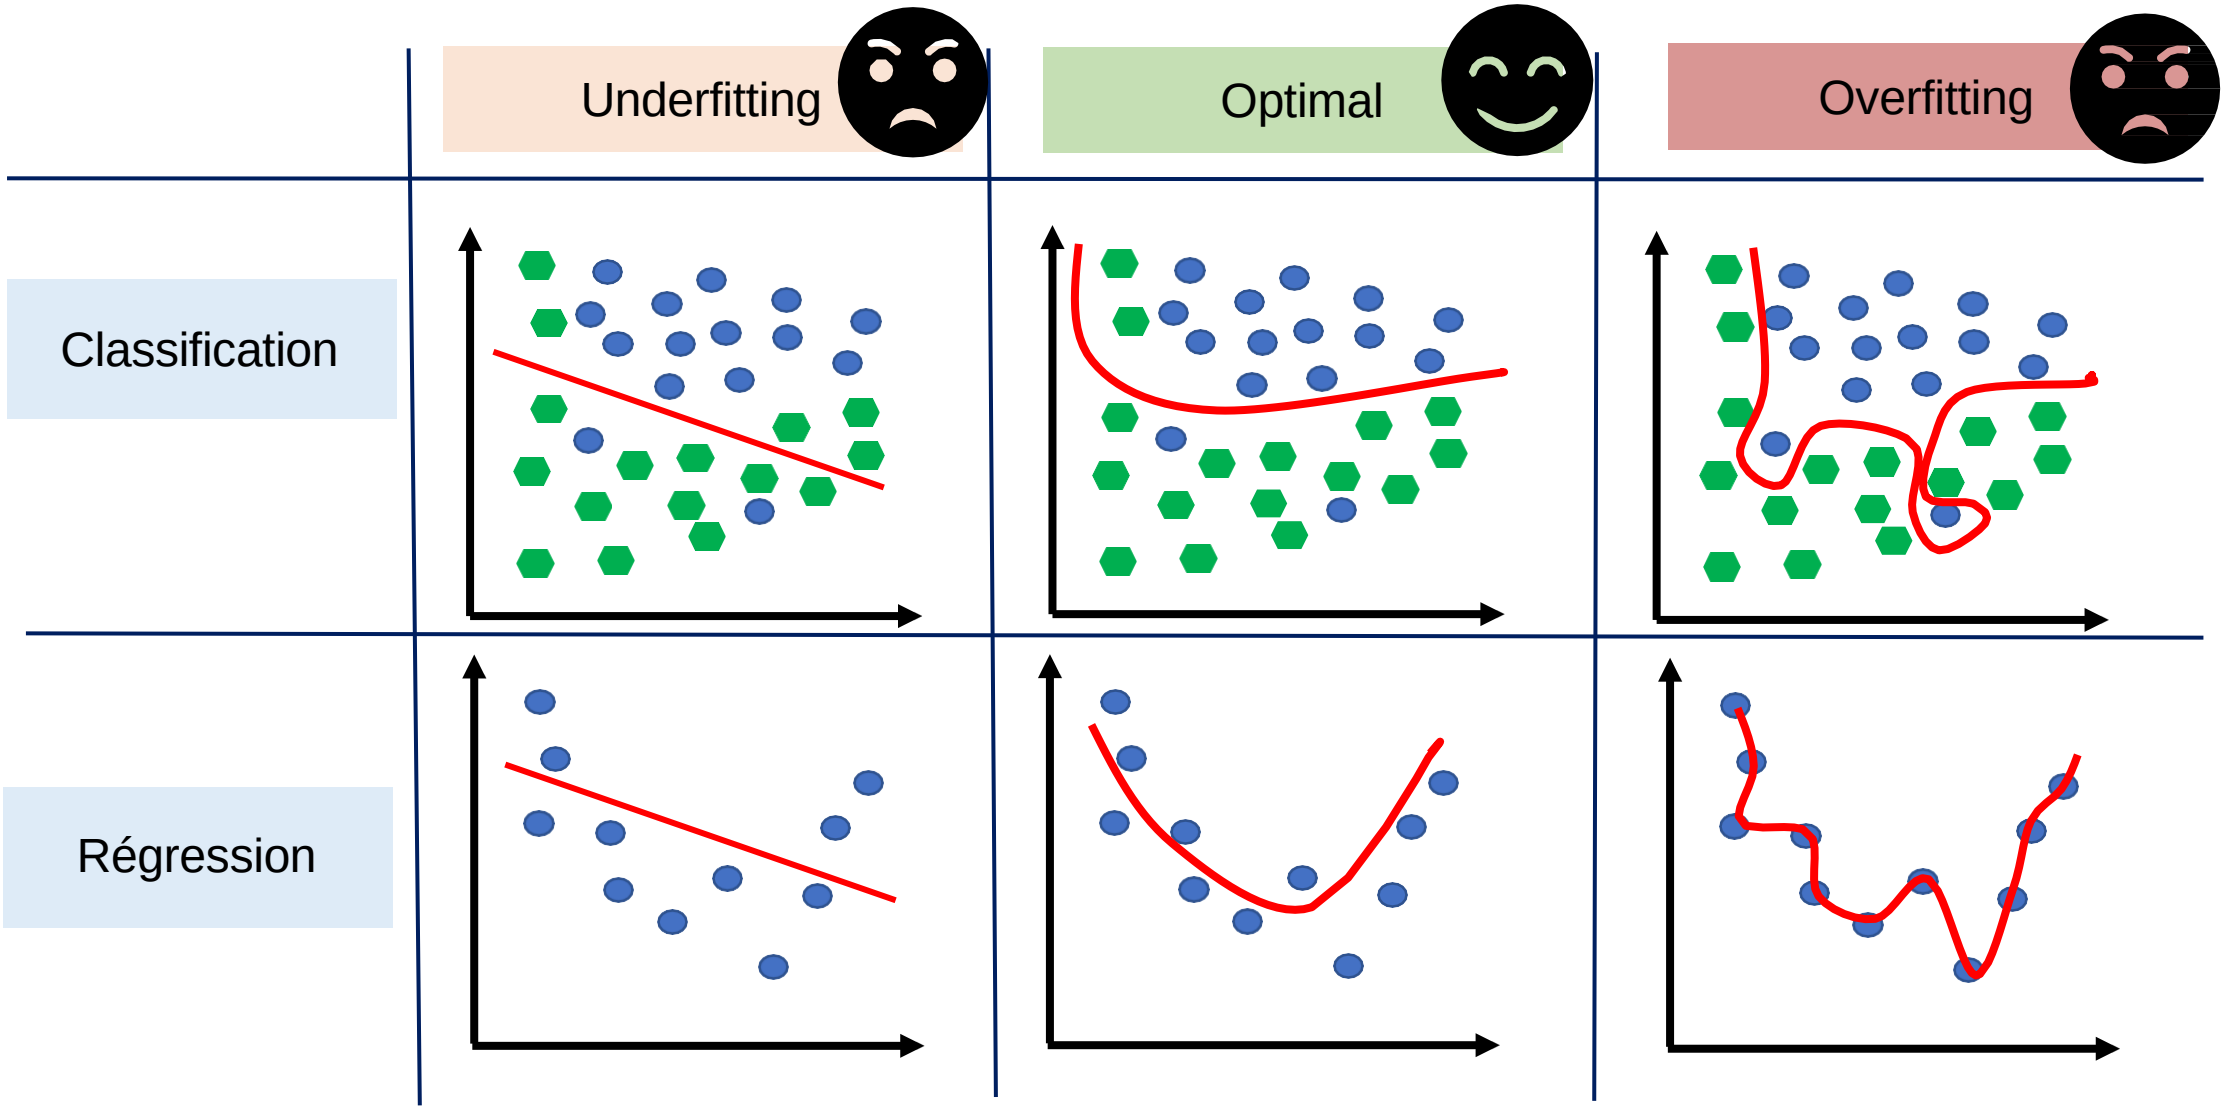

Le bon modèle ? Toujours à vérifier sur un jeu de données externe !

Machine Learning, vocabulaire

Biais élevé : lié à un algorithme qui manque de relations pertinentes entre les données en entrée et les sorties prévues

Variance élevée : modélisation le bruit aléatoire des données

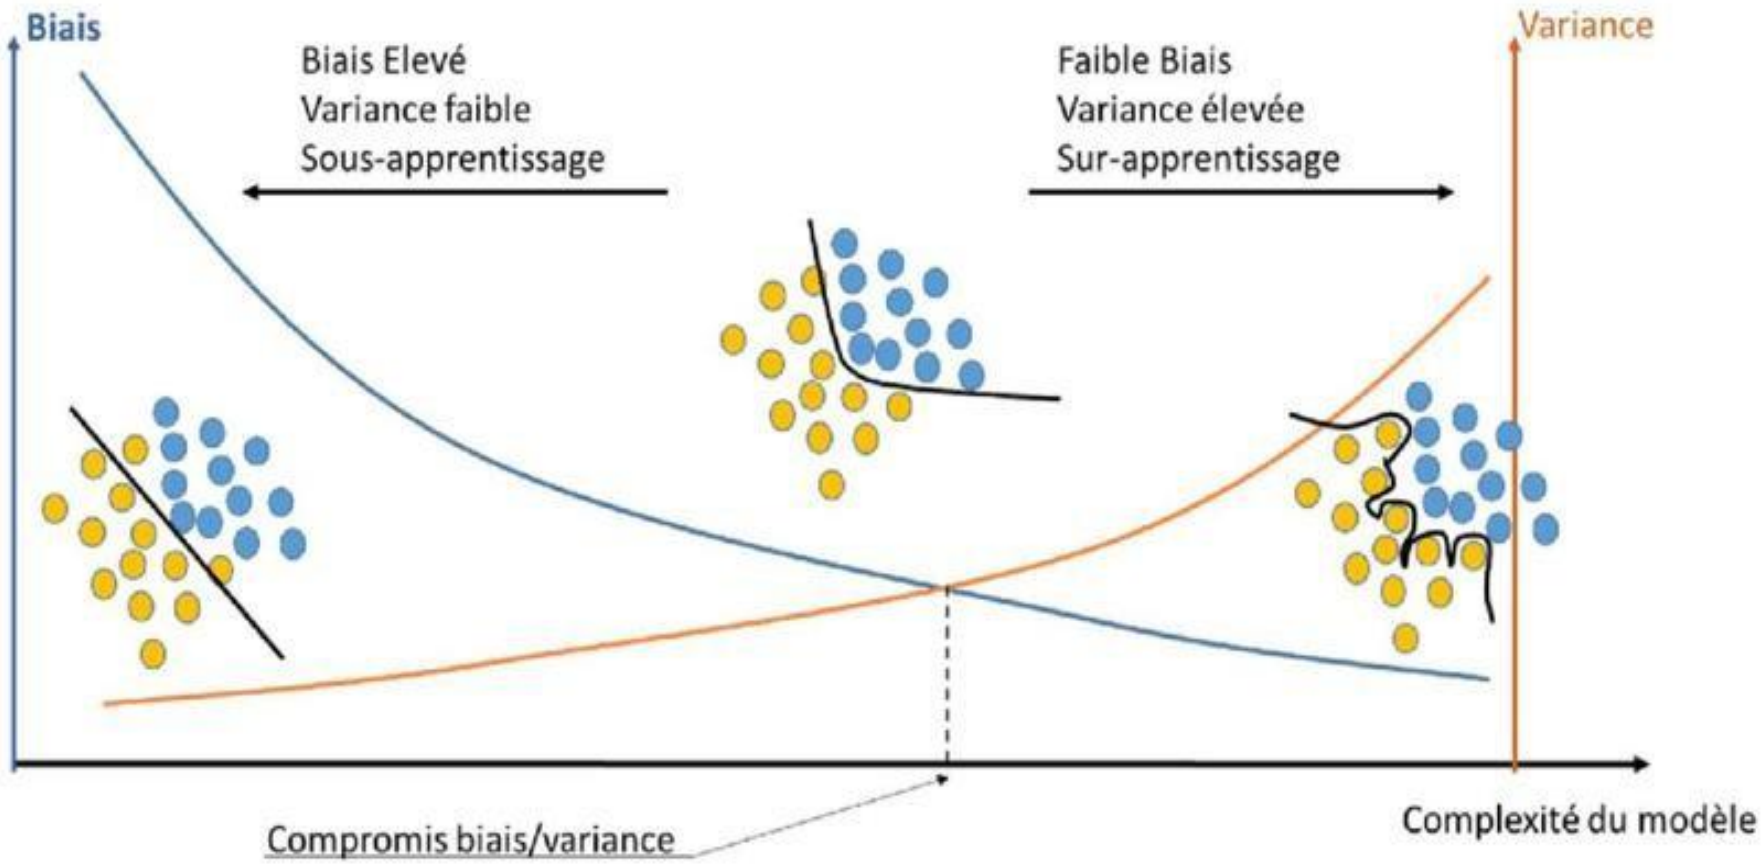

Take-Home message 2, workflow simplifié pour le Machine Learning

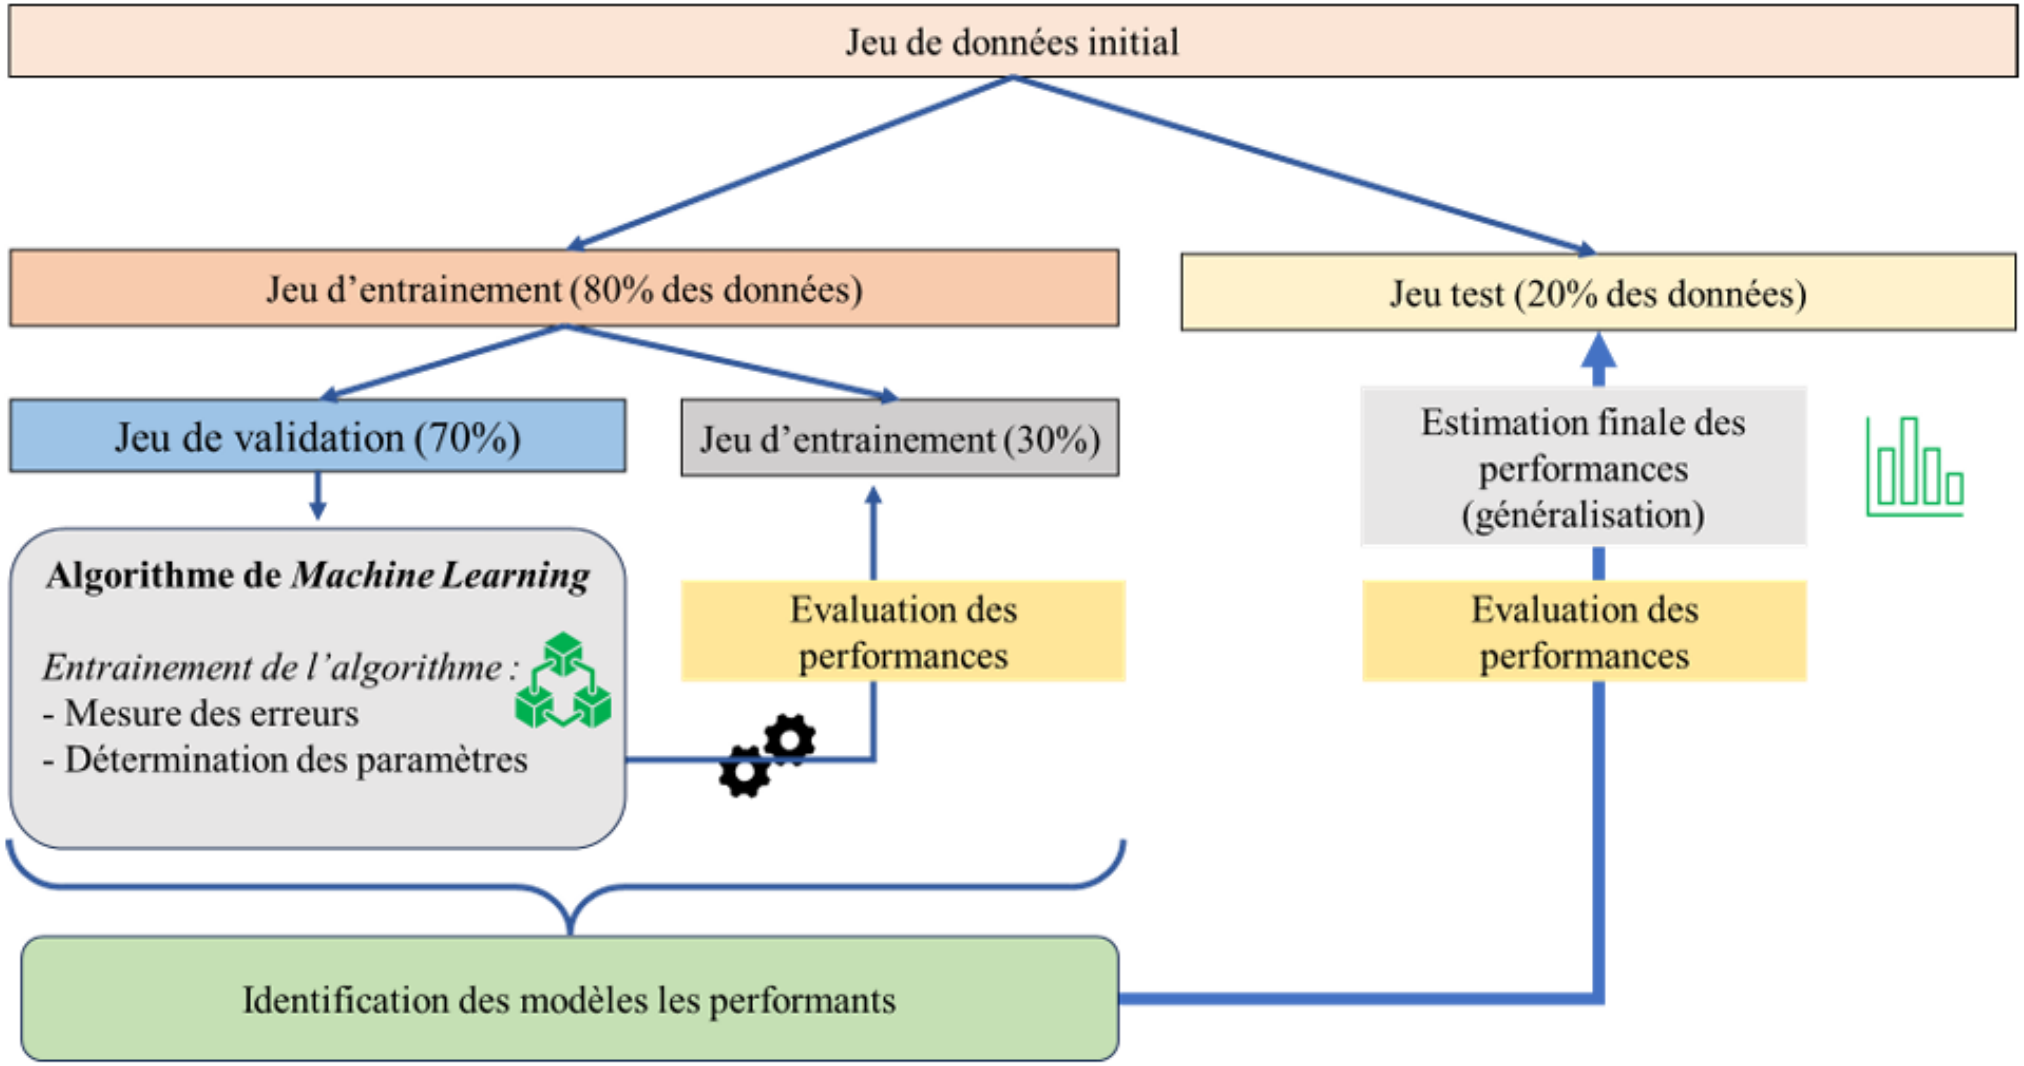

Machine Learning, exercice

Vous développez un test moléculaire avec

- **une sensibilité de 98%,**
- **une spécificité de 95%,**
- **la fréquence de la maladie grave étudiée est de 6%**

Calculer la VPN et la VPP de ce test pour 1000 sujets représentatifs de la population générale

Machine Learning, exercice

Vous développez un test moléculaire avec une sensibilité de 98%, une spécificité de 95%, la fréquence de la maladie grave étudiée est de 6%, calculer la VPN et la VPP de ce test pour 1000 sujets représentatifs de la population générale

	Gold standard		Calcul
Test moléculaire	VP = 60*0,98 = 59	FP = 47	VPP = 59/(59+47) = 0,57
	FN = 1	VN = 940*0,95=893	VPN = 893/(1+893) = 0,99

Quel(s) langage(s) de programmation ? (1)

TIOBE
the software quality company

Oct 2022	Oct 2021	Change	Programming Language	Ratings	Change
1	1		Python	17.08%	+5.81%
2	2		C	15.21%	+4.05%
3	3		Java	12.84%	+2.38%
4	4		C++	9.92%	+2.42%
5	5		C#	4.42%	-0.84%
6	6		Visual Basic	3.95%	-1.29%
7	7		JavaScript	2.74%	+0.55%
8	10	^	Assembly language	2.39%	+0.33%
9	9		PHP	2.04%	-0.06%
10	8	v	SQL	1.78%	-0.39%
11	12	^	Go	1.27%	-0.01%
12	14	^	R	1.22%	+0.03%
13	29	^^	Objective-C	1.21%	+0.76%
14	13	v	MATLAB	1.18%	-0.02%

HTML

Java

https://www.tiobe.com/tiobe-index/

Quel(s) langage(s) de programmation ? (2)

Python

- Créé en 1989 par Guido van Rossum
- Langage multiplateformes
- Langage orienté objet
- Gratuit, simple à prendre en main
- Syntaxe claire, simple
- Utilisation de bibliothèques extérieures (modules) = multiples fonctionnalités

https://commons.wikimedia.org/wiki/File:Guido-portrait-2014-drc.jpg?uselang=fr

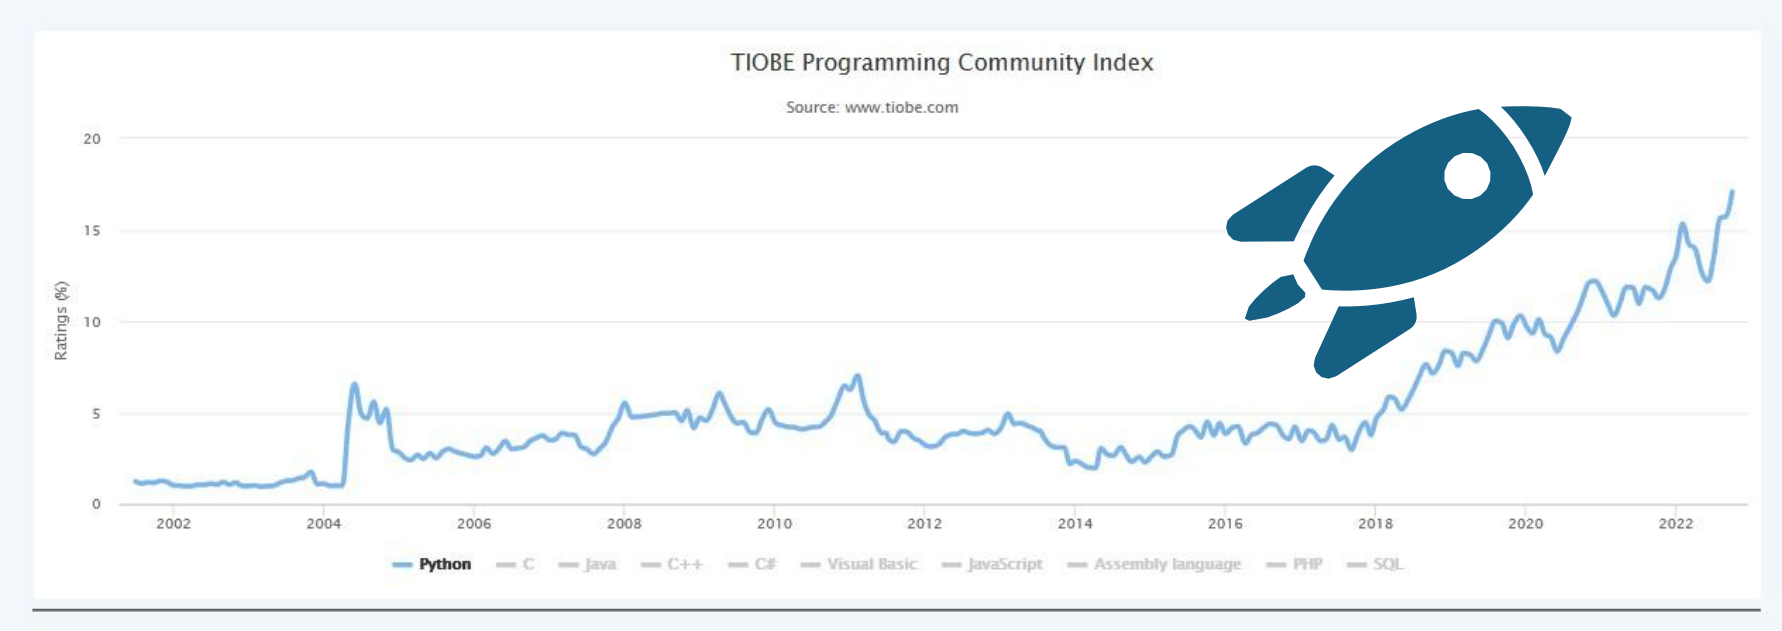

https://www.allocine.fr/film/fichefilm-248/dvd-blu-ray/?cproduct=9802

https://www.tiobe.com/tiobe-index/

Methodologie Deep Learning

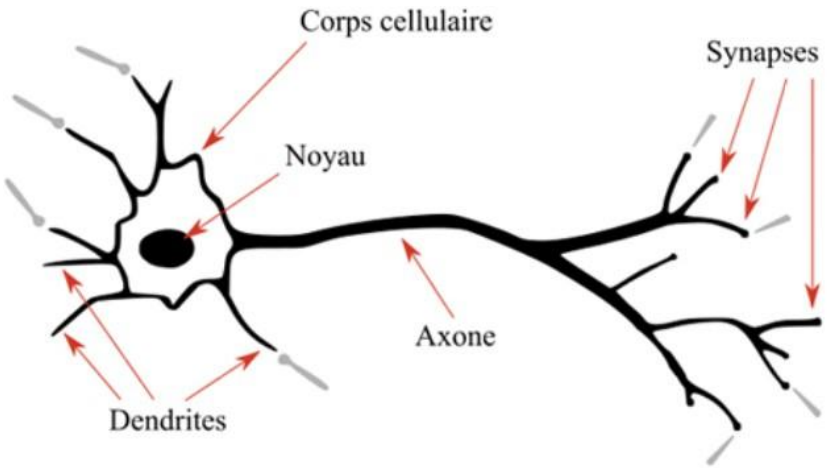

NEURONE BIOLOGIQUE

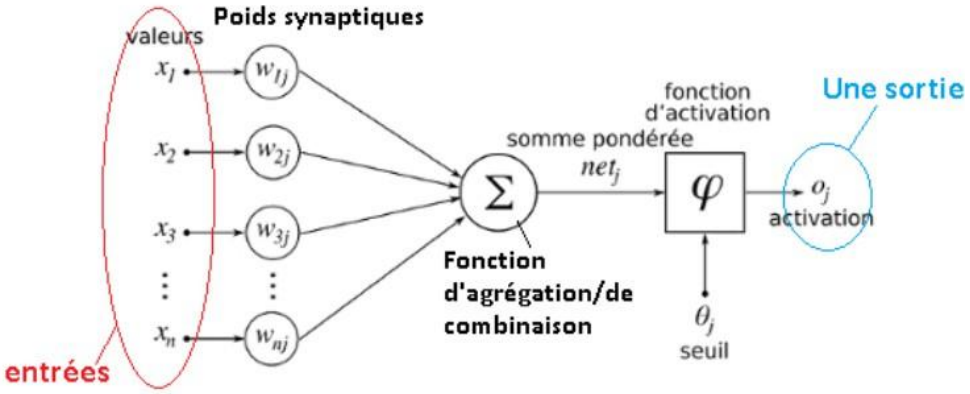

NEURONE ARTIFICIEL

= Perceptron

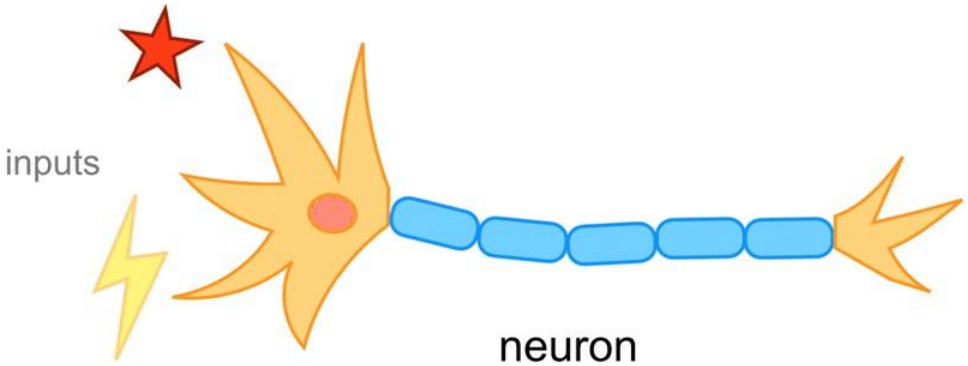

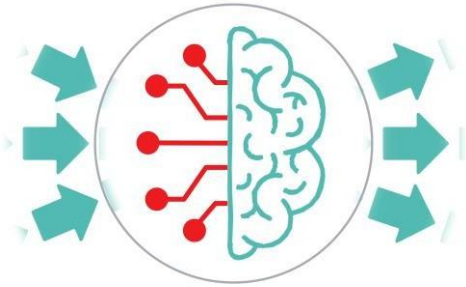

https://www.stemmer-imaging.com/fr-ch/donnees/cvb-polimago-ou-deep-learning/

https://deeplylearning.fr/tag/neurone/

https://www.google.com/search?q=neuron&tbm=isch&hl=fr&tbs=itp:animated&client=firefox-b-d&sa=X&ved=0CAQQpwVqFwoTCJiw88TYjhYCFQAAAAAdAAAAABAC&biw=1263&bih=595#imgrc=ABBp2RQUB_A7IM

Algorithmes de deep learning = analogie avec les neurones biologiques

Methodologie Deep Learning

Train

Backward propagation = ajustement des poids synaptiques

Test

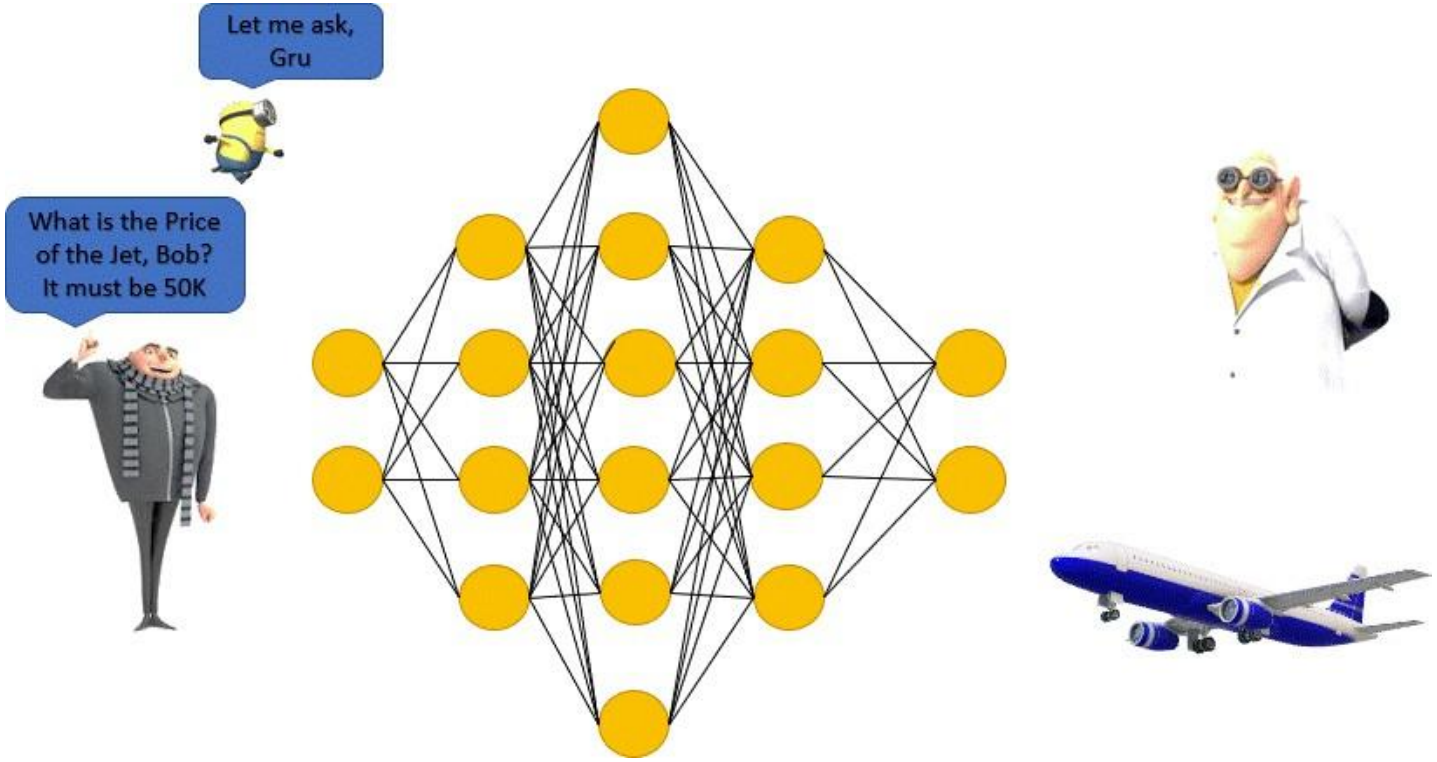

https://1.bp.blogspot.com/-Cehw4NbX2L8/X1-DleQgtmI/AAAAAAAAKoE/fA55qd9EXsgQLU0rbgX_vlkFMwR927yQCLcBGAsYHQ/s853/final.gif

Rétrogradation neuronale = ajustement des poids synaptiques (phase d'entraînement)

Methodologie Deep Learning

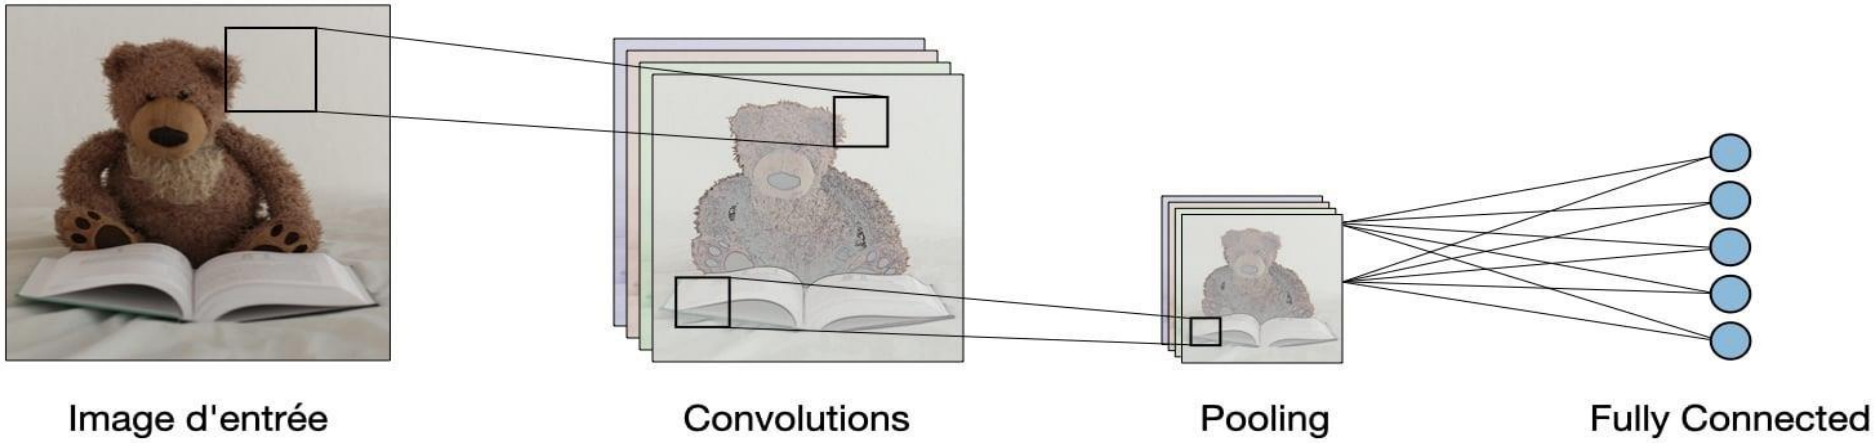

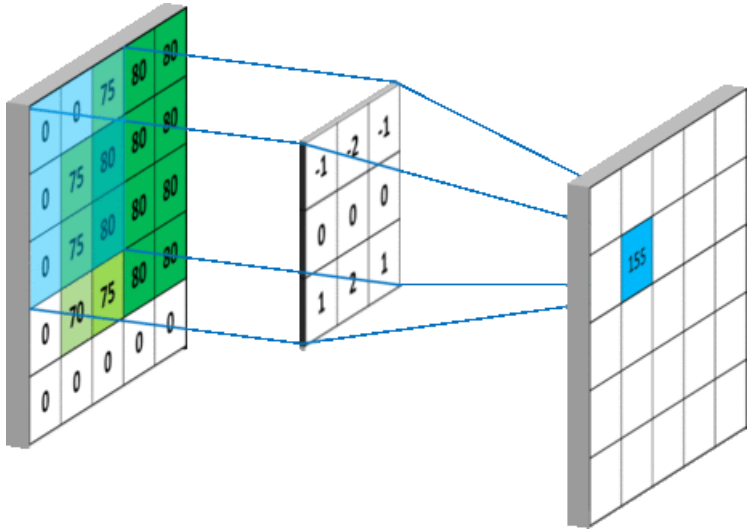

Outil de filtrage qui parcourt la totalité de l'image
:
« carte de caractéristiques »

https://stanford.edu/~shervine/l/fr/teaching/cs-230/pense-bete-reseaux-neurones-convolutionnels

extracteur de features : filtration de l'image

Réseaux de neurones à convolution = inspiré du cortex visuel des animaux

Quel(s) langage(s) de programmation ? (3)

Quelques suggestions pour python :

- Pour l'installation : https://www.anaconda.com/products/distribution
- Utilisation de Jupyter notebook pour la création de notebook
  → contient les résultats de l'exécution
  → facilite le partage, la lisibilité, la documentation du code

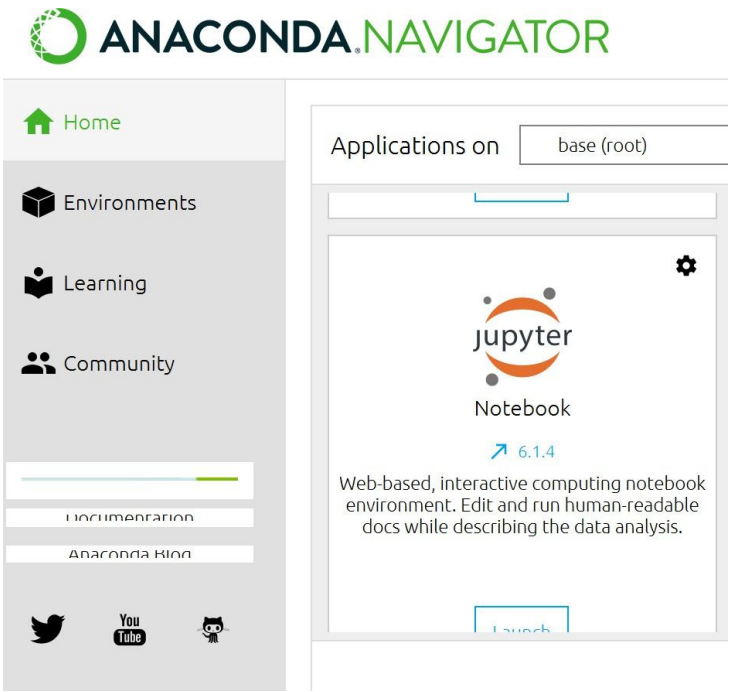

Quel(s) langage(s) de programmation ? (4)

Quelques suggestions pour python :

jupyter WE ARE 2022 Rennes Dernière Sauvegarde : 26/03/2021 (modifié)

File Edit View Insert Cell Kernel Widgets Help

Exécuter Code

Example de notebook

Entrée [1]:
```
# Ajouter un commentaire
a = 2+3
print(a)
```

```
5
```

Entrée [ ]:

Entrée [2]:
```
# Importer fonctions provenant des modules
import matplotlib.pyplot as plt
import numpy as np
```

Entrée [6]:
```
x = np.linspace(1, 100, 100)
y = np.cos(x)
```

Entrée [7]:
```
plt.plot(x, y)
```
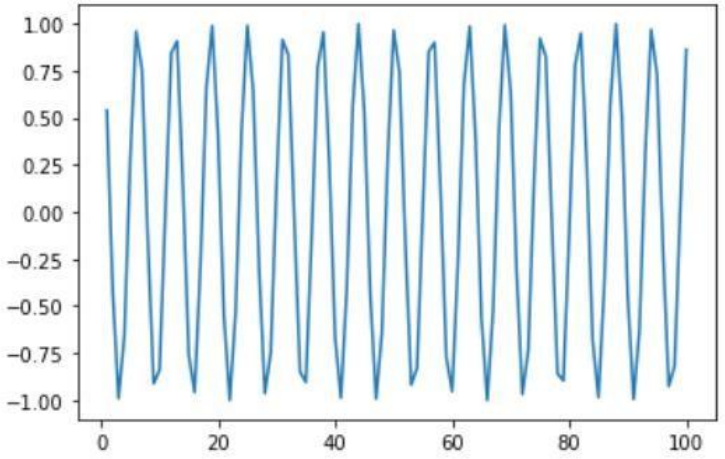
Out[7]:
```
[<matplotlib.lines.Line2D at 0x21840f08520>]
```